Správnost citací AI asistentů s webovým vyhledáváním

Jan Dub[1], **René Mrákava**[1], and **Nikolas Nosál**[1]

[1]Mendelova univerzita v Brně, Provozně ekonomická fakulta

Abstract

Projekt měří, jak často citace AI asistentů s webovým vyhledáváním (ChatGPT, Gemini, Claude, Perplexity, Grok) skutečně podporují tvrzení, ke kterým jsou připojeny. Porovnáváme produkty jako celky na 40 faktických rešeršních dotazech v češtině a angličtině a ve třech promptových podmínkách. Hlavní metrikou je citační přesnost na úrovni tvrzení, doplněná úplností citací a správností odpovědi.

Keywords správnost citací, atribuce zdrojů, generativní vyhledávače, jazykové modely s vyhledáváním, halucinace

1. Úvod a výzkumná otázka

1.a. Shrnutí

Projekt měří, jak často citace AI asistentů s webovým vyhledáváním skutečně podporují tvrzení, ke kterým jsou připojeny. Volíme **Směr B: Výzkum podložený zdroji** a jednu schopnost: správnost a úplnost citací. Porovnáváme produkty jako celky (model + vyhledávání + rozhraní), nikoli samotné jazykové modely.

1.b. Výzkumná otázka

> **Important**
>
> Jak často citovaný zdroj skutečně podporuje tvrzení, ke kterému ho asistent připojil (**citační přesnost**), u pěti AI asistentů s webovým vyhledáváním (ChatGPT, Gemini, Claude, Perplexity, Grok) na 40 faktických rešeršních dotazech v češtině a angličtině z pěti oblastí a o kolik ji mění strukturovaný a optimalizovaný prompt?

Prvek otázky	Naše volba
Hodnocená schopnost	Správnost citací na úrovni tvrzení (podporuje citovaný zdroj tvrzení?) a úplnost citací
Populace úloh	40 faktických rešeršních dotazů, CZ/EN, 5 oblastí, 45 % okrajových případů
Systémy a podmínky	5 asistentů × 3 podmínky promptu (P1 společný, P2 strukturovaný, P3 optimalizovaný)

ENC-AI Project

Published Oct 12, 2026

Acknowledgements
Mendelova univerzita v Brně, Provozně ekonomická fakulta. Všichni autoři přispěli k vypracování zadání.

Data Availability
Protokol, data, prompty, skripty a testy jsou dostupné na https://github.com/Nouzl0/ENC-AI-Project.

Prvek otázky	Naše volba
Měřitelný výsledek	Citační přesnost = podíl dvojic tvrzení–citace hodnocených jako „plně podpořeno“
Význam	Uživatelé citace často neotevřou a berou je jako důkaz. Nepodporující citace tak vytváří falešnou důvěru. Výsledek ukáže, kterému produktu a jakému zadání lze při rešerši víc věřit.

Neptáme se, který asistent je obecně „nejlepší“. Závěry platí jen pro tuto sadu dotazů, tento protokol a období běhů.

1.c. Cíle

1. Změřit citační přesnost a úplnost citací pěti produktů na stejné sadě dotazů.
2. Zjistit, zda strukturovaný (P2) a optimalizovaný (P3) prompt citační přesnost zvyšuje, a zda je zlepšení přenositelné mezi systémy.
3. Popsat, jaké typy chyb citací se opakují (viz Analýza chyb).

1.d. Hypotézy

Předem registrujeme jednu hlavní hypotézu o systémech, jednu vedlejší o promptech a dvě alternativní vysvětlení. Všechny se vyhodnocují na testovací sadě držené stranou.

1.d.i. *Alternativní vysvětlení:*

Alternativní vysvětlení	Jak by vypadalo v datech	Jak ho kontrolujeme
A1 – opatrnost místo kvality: systém má vyšší přesnost jen proto, že dělá méně a obecnějších tvrzení nebo cituje méně	Vysoká přesnost, ale nízká úplnost citací a málo tvrzení na odpověď	Vždy vykazujeme přesnost spolu s úplností, počtem tvrzení a pokrytím klíčových faktů (kolik faktů z `key_facts` odpověď uvádí a dokládá citací S2)
A2 – dostupnost zdrojů: rozdíl způsobí paywally, blokování crawlerů nebo slabší index českých stránek, ne přiřazování citací	Rozdíly se soustředí v českých dotazech a v kategorii „nedostupný zdroj“	Nedostupné zdroje evidujeme zvlášť (hodnocení NA) a výsledky rozdělujeme na CZ a EN

2. Porovnávané systémy a přístup k nástrojům

Volíme návrh podle schopností produktu: každý asistent používá své běžné webové vyhledávání a výsledky prezentujeme výslovně jako **porovnání produktů**. Paritu nástrojů ve spotřebitelských rozhraních zajistit nelze, protože každý produkt má vlastní vyhledávač, index a zobrazení citací. Claude Code nezahrnujeme, protože jde o nástroj pro programování.

Systém	Jak zajistit vyhledávání	Režim bez paměti	Vyloučený režim
ChatGPT	Vynutit nástrojem Search (menu nástrojů nebo „/“)	Temporary chat, varianta Unpersonalized	Deep research
Gemini	Automaticky, přepínač není zdokumentován	Temporary chat (osobní účet)	Deep Research
Claude	Přepínač Web search, v novém rozhraní automaticky	Incognito chat a smazané preference a styly profilu	Research
Perplexity	Vždy, režim Search	Incognito	Research, Labs
Grok	Automaticky (web a X)	Private Chat	DeepSearch

Note

Nastavení odpovídá nápovědě výrobců k 29. 9. 2026. První den běhů ho ověříme snímkem obrazovky, protože se rozhraní mění.

2.a. Pravidla běhu

1. Každý dotaz začíná v novém chatu v režimu bez paměti, bez vlastních instrukcí, bia a stylů. Použijeme nové účty s vypnutou pamětí.
2. Všechny systémy běží na stejné úrovni předplatného, výchozí je bezplatná. Model necháme na automatickém výběru a zaznamenáme jeho viditelný název.
3. Použijeme stejný prohlížeč, českou síť a češtinu rozhraní. Pořadí systémů pro každý případ losuje skript (seed 2026).
4. Jeden případ projde všemi pěti systémy během 24 hodin, celou testovací sadu zvládneme do 72 hodin.
5. Platí jedno kolo komunikace. Pokud se systém doptá, odpovíme větou „Pokračujte podle svého nejlepšího úsudku.“ a kolo navíc zaznamenáme.
6. Uložíme text odpovědi, všechny URL citací (z panelu zdrojů nebo exportu), snímek obrazovky a odkaz na sdílení.

2.b. Co lze od čeho oddělit

Zdroj výkonnosti	Oddělíme ho?	Jak
Vliv promptu	Ano	Stejný systém v podmínkách P1, P2 a P3
Vliv nástrojů	Částečně	Evidujeme, zda proběhlo vyhledávání a kolik zdrojů systém zobrazil

Zdroj výkonnosti	Oddělíme ho?	Jak
Schopnost modelu	Ne	Ve spotřebitelském rozhraní model nelze odpojit od vyhledávání
Vliv produktu	Ne	Rozhraní, bezpečnostní vrstva a vyhledávač tvoří celek

2.c. Metadata běhů

Metadata každého běhu zapisujeme do `runs/run_plan_<fáze>.csv`:

- systém, viditelný název modelu, rozhraní a úroveň předplatného,
- datum a čas (Europe/Prague),
- podmínku a verzi promptu s hashem SHA-256 a systémovou instrukci („výchozí, neviditelná“),
- oprávnění nástrojů, kontextové soubory (žádné), teplotu a délku výstupu („výchozí, nenastavitelné“),
- počet kol, počet zobrazených vyhledávání, latenci, náklady,
- opakování, typ selhání a ruční zásahy.

2.d. Volitelné rozšíření: API

Stejnou sadu lze spustit přes API s nástroji pro webové vyhledávání (OpenAI, Gemini, Anthropic, xAI). API dovolí nastavit teplotu a délku výstupu a vrací strukturovaná metadata citací. Výsledky API bychom vykazovali odděleně jako druhou vrstvu (dvouvrstvý návrh) a neslévali je s výsledky produktů.

3. Testovací sada

Sada má 40 případů v rozdělení 20/10/10 (vývoj / validace / test držený stranou) a 18 z nich (45 %) testuje okrajovou podmínku. Každá část pokrývá všech pět oblastí rovnoměrně. Referenční odpovědi a zlaté zdroje jsme ověřili na otevřených primárních zdrojích 29. 9. 2026.

Vlastnost	Vývoj (20)	Validace (10)	Test držený stranou (10)
Oblasti: věda a zdraví / právo / IT / ekonomika / historie a kultura	4 / 4 / 4 / 4 / 4	2 / 2 / 2 / 2 / 2	2 / 2 / 2 / 2 / 2
Jazyk: CZ / EN / CZ+EN	10 / 9 / 1	5 / 4 / 1	5 / 5 / 0
Typ: fakt / primární zdroj / syntéza	10 / 6 / 4	3 / 4 / 3	5 / 4 / 1
Obtížnost: snadná / střední / těžká	3 / 11 / 6	4 / 4 / 2	3 / 3 / 4
Okrajové případy	9 (45 %)	4 (40 %)	5 (50 %)

Table 1: Složení testovací sady

3.a. Okrajové případy

Okrajový případ	Počet	Příklad z vývojové sady	Co je správné chování
Nepravdivý předpoklad	3	„Proč musí mít kandidát do Senátu ČR alespoň 35 let?“	Opravit na 40 let, čl. 19 odst. 2 Ústavy
Protichůdné zdroje	3	Nadmořská výška Sněžky (1602 vs. 1603 m)	Uvést obě hodnoty a důvod rozdílu
Chybějící informace	4	Přesné datum narození Shakespeara	Přiznat, že není známo; uvést křest 26. 4. 1564
Nejednoznačné zadání	2	„Kdy vznikla Česká republika?“	Rozlišit 1969, 1990 a 1993
Časové omezení	2	Aktuální sazba ECB, jen zdroje z posledních 30 dní	Uvést hodnotu, datum účinnosti a datum zdroje
Nedávná změna faktu	2	Podpora Windows 10 a program ESU (prodloužen do 2027)	Uvést aktuální stav, ne zastaralý
Kombinace češtiny a angličtiny	2	Co znamená SBOM a který exekutivní příkaz ho prosadil	Odpovědět česky, termíny ponechat

3.b. Schéma případu

Schéma odpovídá zadání: `task_id`, `capability`, `task_type`, `difficulty`, `language`, `development_validation_test_split`, `user_prompt`, `context_or_files`, `expected_properties`, `reference_answer_or_tests`, `edge_case_type`, `evaluation_method` a `source_or_provenance`. Přidali jsme `domain`, `key_facts`, `gold_sources` a `reference_valid_as_of`.

3.c. Ochrana testovací sady

- Testovací případy v tomto dokumentu neuvádíme. Jsou jen v souboru `data/cases_test.jsonl`. Správce dat ho po stažení balíčku přesune mimo sdílenou složku a do G2 v ní nechá jen hash.
- Autor promptu P3 soubor neotevře, dokud není P3 zmrazený.
- Hash SHA-256 souboru zapíšeme do protokolu před prvním během. Skript `validate_cases.py` hlídá, aby se test nepřekrýval s vývojem (podobnost otázek nad 0,5).

Navedení v otázce

Část případů s protichůdnými zdroji rozpor v otázce záměrně nenaznačuje. Jinak by P2 (pravidla 5–8) zvýhodňovalo jen to, že systém dostane nápovědu. Testovací sada pokrývá 5 ze 7 typů okrajových případů; nejednoznačné zadání a kombinaci češtiny s angličtinou vyhodnotíme jen popisně na vývoji a validaci.

Dynamické případy

Sazba ECB a míra nezaměstnanosti se mění. Hodnotitel proto ověří referenci v den běhu na oficiální stránce uvedené v `gold_sources`.

3.d. Etika dat

Všechny dotazy jsou syntetické a vytvořil je tým. Ptáme se jen na veřejně dostupná fakta, bez osobních údajů, důvěrných dat a autorsky chráněných textů. Ke každému případu uvádíme původ a datum ověření.

4. Podmínky promptů

Všechny tři podmínky dostanou stejnou otázku a liší se jen obalem kolem ní. Anglické případy používají překlad stejného textu, všechny verze jsou v `prompts/`. Systémově specifické úpravy nepovolujeme (cíl je 0).

4.a. P1 – společná výchozí podmínka

Šablona ze zadání a jedna věta o formátu:

```
Vyřešte níže uvedenou úlohu. Odpovězte pouze v požadovaném formátu.

Úloha:
{user_prompt}
Formát: stručná odpověď s odkazy na použité zdroje (URL).
```

4.b. P2 – strukturovaný prompt

Verze 1.0, napsána před prvním během:

```
Jste pečlivý rešeršní asistent. Každé tvrzení dokládáte zdrojem, který
jste v této konverzaci skutečně otevřeli.

Cíl: odpovězte přesně a stručně na otázku tak, aby si čtenář mohl každé
tvrzení ověřit.

Otázka:
{user_prompt}

Pravidla:
1. Vyhledejte informace na webu. Necitujte zdroj, který jste neotevřeli,
a nevymýšlejte URL.
2. Za každým faktickým tvrzením (číslo, datum, jméno, definice) uveďte
odkaz na zdroj ve tvaru [1], [2].
3. Citujte konkrétní stránku nebo dokument, ne domovskou stránku ani
výsledky vyhledávání.
4. Upřednostňujte primární a oficiální zdroje (zákon, úřad, původní
studie, standard).
5. Pokud otázka obsahuje chybný předpoklad, nejprve ho opravte.
6. Pokud se zdroje liší, uveďte obě hodnoty, každou s vlastním zdrojem,
a vysvětlete rozdíl.
7. Pokud otázka omezuje stáří zdrojů, použijte jen zdroje, které omezení
splňují, a uveďte jejich datum.
8. Pokud spolehlivou odpověď nenajdete, napište to. Nehádejte.

Formát výstupu:
ODPOVĚĎ: 1–3 věty s přímou odpovědí.
TVRZENÍ:
T1: <jedno tvrzení> [n]
T2: <jedno tvrzení> [n]
ZDROJE:
[1] <název> – <vydavatel> – <datum vydání nebo „neuvedeno"> – <úplná
URL>
JISTOTA: vysoká / střední / nízká – jedna věta proč.
```

4.c. P3 – optimalizovaný prompt

P3 vznikne z P2 jen na základě vývojové a validační sady:

1. Po běhu P2 na vývojové sadě sečteme typy chyb (taxonomie viz Analýza chyb). Úprava je povolená jen proti typu chyby, který se objevil alespoň třikrát.
2. Připravíme dva kandidáty. Předpokládaný **P3-A** přidá ke každému tvrzení doslovný úryvek ze zdroje (nejvýš 25 slov). **P3-B** přidá navíc kontrolu před odesláním: tvrzení, které citovaná stránka neobsahuje, se odstraní nebo označí jako nepodložené. Konečné úpravy určí data z vývoje.
3. Kandidáty spustíme na validační sadě spolu s P2. Vybereme kandidáta s vyšší citační přesností; při rozdílu pod 2 procentní body rozhodne kratší prompt.
4. Vítěze zmrazíme, zapíšeme jeho hash SHA-256 a teprve pak otevřeme testovací sadu. Pokud žádný kandidát nepřekoná P2, použijeme lepšího z nich a vykážeme neúspěšnou optimalizaci jako výsledek. Jedno další kolo úprav je povolené jen na vývojové sadě. Každou změnu a její důvod zapíšeme do `prompts/CHANGELOG.md`.

> **Warning**
>
> P3 nesmí obsahovat pokyny pro konkrétní případy ani informace, které by prozradily odpovědi.

4.d. Přenositelnost

Přenositelnost vykazujeme pro P2 i P3:

- průměrné zlepšení oproti P1,
- zlepšení podle jednotlivých systémů a na testovací sadě,
- délku promptu ve znacích,
- počet systémově specifických úprav,
- dodatečná kola komunikace.

Prompt, který jednomu systému pomůže a ostatním uškodí, vykazujeme jako platný výsledek, ne jako lepší obecný prompt.

5. Metriky

Hlavní metrikou je citační přesnost na úrovni tvrzení. Vedlejší metriky jsou úplnost citací a správnost odpovědi. Všechny definice a váhy platí od zmrazení protokolu, před prvním testovacím během.

5.a. Jednotky hodnocení

Tvrzení Atomický faktický výrok: číslo, datum, jméno, definice nebo vztah. Složené věty dělíme. Skript navrhne dělení (u P2 a P3 ze seznamu TVRZENÍ, u P1 po větách), hodnotitel ho pak u všech podmínek upraví podle stejných pravidel v rubrice. Jinak by rozdíl P1 a P2 měřil i způsob dělení. Hodnotíme nejvýš 8 tvrzení na odpověď v pořadí výskytu.

Dvojice tvrzení–citace Tvrzení a zdroj, který k němu systém připojil. Uvede-li systém zdroje jen souhrnně na konci, spárujeme tvrzení s nejlépe odpovídajícím uvedeným zdrojem a označíme citaci jako nepřiřazenou.

Hodnocení dvojice **S2** plně podpořeno, **S1** částečně podpořeno, **S0** nepodpořeno nebo v rozporu, **NA** zdroj nedostupný, **FAB** zdroj neexistuje.

5.b. Hlavní metrika – citační přesnost

Pro každou odpověď a počítáme podíl dvojic hodnocených S2, pro systém a podmínku pak průměr přes případy. Každý případ má stejnou váhu a opakované běhy nejprve zprůměrujeme v rámci případu.

$$\text{Přesnost}_a = \frac{|\ \text{dvojice odpovědi } a \ \text{ s hodnocením S2}|}{|\ \text{všechny dvojice odpovědi } a\ |} \tag{1}$$

NA a FAB se počítají jako selhání, protože čtenář si tvrzení nemůže ověřit. Odpověď bez jediné citace má přesnost 0, protože citace byly součástí zadání. V citlivostní analýze přesnost přepočítáme bez NA.

5.c. Vedlejší metriky

Úplnost citací měří, kolik tvrzení je podloženo alespoň jednou citací S2. Tvrzení bez citace má hodnotu 0.

$$\text{Úplnost}_a = \frac{|\ \text{tvrzení odpovědi } a \ \text{ s alespoň jednou citací S2}|}{|\ \text{všechna hodnocená tvrzení odpovědi } a\ |} \tag{2}$$

Správnost odpovědi je podíl odpovědí se skóre 2 na škále 0–2 proti referenci a `key_facts`. U nepravdivého předpokladu musí systém předpoklad opravit. U chybějící informace musí přiznat, že přesná odpověď neexistuje.

5.d. Diagnostické metriky

Diagnostická metrika	Definice	Proč ji sledujeme
Míra neexistujících zdrojů	Podíl citací s hodnocením FAB	Halucinace citací
Míra nedostupných zdrojů	Podíl citací s hodnocením NA	Kontrola alternativy A2
Kvalita zdrojů	Podíl citací na primární nebo oficiální zdroj	Upřednostnění důvěryhodných zdrojů

Diagnostická metrika	Definice	Proč ji sledujeme
Dodržení časového omezení	Podíl citací, které splňují limit stáří	Případy s časovým omezením
Vhodné přiznání nejistoty	Podíl odpovědí na chybějící nebo nejednoznačné dotazy, které nejistotu přiznají	Práce s nejistotou
Tvrzení a citace na odpověď	Průměrný počet	Kontrola alternativy A1
Nepřiřazené citace	Podíl citací uvedených jen souhrnně	Granularita citování

5.e. Provozní metriky

Medián a 90. percentil latence (od odeslání po dokončení odpovědi, měřeno stopkami), počet kol, počet zobrazených vyhledávání, odhad nákladů (cena plánu dělená počtem dotazů), míra opakování a čas lidské kontroly na odpověď.

Užitek má váhy stanovené předem. L_{norm} je medián latence systému dělený nejvyšším mediánem, T_{norm} je medián času lidské kontroly dělený nejvyšším mediánem. Vedle užitku uvedeme i Pareto-frontu přesnosti proti latenci.

$$\text{Užitek} = \text{Přesnost} - 0,1 \cdot L_{\text{norm}} - 0,1 \cdot T_{\text{norm}} \tag{3}$$

6. Automatizované kontroly a lidské hodnocení

Skripty dělají mechanickou práci: rozdělí odpověď na tvrzení, zkontrolují URL a zaslepí listy. Hodnocení S2 až FAB a správnost odpovědi vždy zapisuje člověk.

6.a. Automatizované kontroly

Skript `check_citations.py` zkontroluje každou citaci před lidským hodnocením a výsledky zapíše do anotačního listu. Automatika lidské hodnocení nenahrazuje, jen ho předvyplňuje a zrychluje. Konečné hodnocení vždy potvrzuje člověk.

Kontrola	Co skript dělá	Výsledek
Dostupnost URL	HTTP stav a přesměrování, dva pokusy s odstupem 10 minut	404, 410 nebo chyba DNS: návrh FAB k ručnímu ověření; 401, 403 nebo paywall: návrh NA
Konkrétnost odkazu	Pozná domovskou stránku a stránku s výsledky vyhledávání	Příznak „obecná citace“
Shoda čísel a jmen	Vytáhne z tvrzení čísla, data a vlastní jména a hledá je v textu stránky (sjednotí „1 603″ a „1603″, čárku a tečku)	Podíl nalezených entit, předběžný příznak shody
Datum publikace	Čte metadata stránky (`article:published_time`, `datePublished`)	Kontrola časového limitu
Formát P2 a P3	Ověří sekce ODPOVĚĎ, TVRZENÍ, ZDROJE a JISTOTA a že každé [n] má záznam ve zdrojích	Validita formátu jako diagnostika dodržování instrukcí

Další dva skripty doplňují kontrolu dat a výpočet:

- `validate_cases.py` ověří schéma případů, velikost částí, podíl okrajových případů (alespoň 20 %), podobnost testu s vývojem a spočítá hash testovací sady.
- `score.py` spočítá metriky, intervaly nejistoty a shodu hodnotitelů.

Validace automatiky: na vývojové sadě porovnáme příznak shody čísel s lidským hodnocením S2. Pokud bude shoda slabá (kappa pod 0,4), použijeme příznak jen jako nápovědu pro hodnotitele.

6.b. Lidské hodnocení

Člověk hodnotí to, co automatika spolehlivě nezměří: zda citovaný zdroj tvrzení skutečně podporuje. Rubrika platí od zmrazení protokolu a plné znění s dalšími příklady je v `annotation/rubric.md`.

Hodnocení	Pravidlo	Kotva (příklad)

Hodnocení	Pravidlo	Kotva (příklad)
S2 plně podpořeno	Zdroj tvrzení výslovně uvádí nebo z něj přímo plyne; čísla sedí v uvedené přesnosti	„Sněžka měří 1603 m“ + stránka ČÚZK s hodnotou 1603,296 m
S1 částečně	Zdroj podporuje jen část tvrzení, nebo je tvrzení silnější či obecnější než zdroj	„Nový stavební zákon platí od 1. 1. 2024 pro všechny stavby“ + zdroj uvádějící jen vyhrazené stavby
S0 nepodpořeno	Zdroj tvrzení neobsahuje nebo mu odporuje	„Poločas rozpadu C-14 je podle NNDC 5 568 let“ + stránka NNDC s hodnotou 5 700 $\pm$ 30 let
NA nedostupné	Stránka existuje, ale obsah nelze přečíst (paywall, přihlášení, chyba 403)	Článek NEJM za paywallem bez abstraktu
FAB neexistuje	URL ani DOI neexistuje a nenašli jsme ji ani v archivu	Vymyšlený DOI nebo URL s chybou 404

Správnost odpovědi (0–2):

- **2** = všechny `key_facts` správně a chybný předpoklad opraven,
- **1** = část klíčových faktů chybí nebo je nepřesná,
- **0** = odpověď je chybná, přijme nepravdivý předpoklad nebo vymýšlí přesnou hodnotu tam, kde neexistuje.

6.b.i. *Postup:*

1. **Kalibrace:** před ostrým hodnocením ohodnotí všichni hodnotitelé stejných 10 odpovědí z vývojové sady a sjednotí výklad rubriky.
2. **Zaslepení:** anotační list neukazuje název systému ani podmínku. Formátování odpovědí sjednotíme na prostý text s označením [n] a seznamem URL.
3. **Náhodné pořadí:** skript zamíchá odpovědi (seed 2026), aby hodnotitel neviděl odpovědi jednoho systému za sebou.
4. **Dva hodnotitelé** pro 25 % odpovědí, vybraných stratifikovaně podle systému a podmínky. Zadání vyžaduje 20 %. Shodu měříme Cohenovou kappou (S2 proti ostatním) a procentem shody. Cílem je kappa alespoň 0,6. Při nižší hodnotě rubriku upřesníme a dvojitě hodnocené odpovědi ohodnotíme znovu.
5. **Řešení neshod:** hodnotitelé neshodu proberou. Když se nedohodnou, rozhodne třetí hodnotitel. Každou neshodu a její řešení zapíšeme do `annotation/disagreements.csv`.

6.b.ii. *Hodnocení pomocí LLM:*

Hlavní závěry stavíme jen na lidském hodnocení. LLM použijeme nanejvýš k předběžnému rozdělení P1 odpovědí na tvrzení, které člověk zkontroluje.

Pokud tým LLM hodnotitele použije i pro podporu citací, uvede model a verzi, použije tuto rubriku a zaslepené a zamíchané odpovědi. Kalibruje ho na 50 dvojicích ohodnocených člověkem a vykáže shodu s lidmi. Zkontroluje i vliv délky odpovědi a sebepreferenci, protože každý dostupný hodnoticí model patří některému z porovnávaných výrobců. LLM hodnotitel je měřicí nástroj s vlastní chybou.

7. Plán běhů a nejistota

Výchozí plán má 500 odpovědí. Hlavní podmínku P2 na testovací sadě spouštíme třikrát, abychom změřili rozptyl mezi běhy.

Fáze	Sada	Podmínky	Běhy	Odpovědí (× 5 systémů)
1 Vývoj	vývojová (20)	P2	1	100
2 Validace	validační (10)	P2, P3-A, P3-B	1	150
3 Test	testovací (10)	P1, P2, P3	1	150
4 Opakování	testovací (10)	P2	2 další	100
			Celkem	**500**

Odhad práce je asi 3 minuty na běh a 7 minut na hodnocení, celkem asi 85 hodin, tedy 21 hodin na člena čtyřčlenného týmu.

Úsporná varianta pro 2–3 členy: čtyři systémy (Grok vynecháme s písemným odůvodněním), jeden kandidát P3 a opakování jen na 5 testovacích případech, celkem 320 odpovědí.

Rozšíření: P1 i na vývojové sadě (+100) zvýší sílu testu H2, protože P1 ani P2 na ní laděné nejsou.

7.a. Metody nejistoty

- **Klastrový bootstrap podle případů:** 10 000 převzorkování testovacích případů s vracením (seed 2026) a percentilový 95% interval. Dvojice tvrzení–citace nejsou nezávislé, proto převzorkováváme celé případy.
- **Párový bootstrap rozdílů** pro H1 (Perplexity minus průměr ostatních) a H2 (P2 minus P1). Všechny systémy řeší stejné případy, takže párování odstraní rozptyl obtížnosti případů.
- **Wilsonův 95% interval** pro binární podíly na úrovni odpovědi, například podíl správných odpovědí nebo odpovědí s alespoň jednou FAB citací.
- **Variabilita mezi běhy:** směrodatná odchylka přesnosti přes tři běhy P2 a podíl případů, kde se správnost odpovědi mezi běhy změní.
- **Shoda hodnotitelů:** Cohenova kappa a procento shody (viz Lidské hodnocení).

Interpretace

S 10 testovacími případy budou intervaly široké a rozdíly pod zhruba 15 procentních bodů pravděpodobně nepůjde rozlišit. Proto uvádíme velikost efektu, interval a praktický význam, ne jen „signifikanci“.

Výsledky P2 z vývojové a validační sady uvedeme jako doplňkové, protože P2 na nich laděný nebyl. U P3 platí jen výsledek z testovací sady.

7.b. Selhání a opakování

Neúspěšný běh je součástí dat. Opakování povolujeme jen u selhání mimo model a vždy vykazujeme úspěšnost na první pokus i po opakování.

Typ selhání	Příklad	Opakování	Jak se počítá
Výstup modelu	Odmítnutí, odpověď bez citací, halucinace	Ne	Hodnotí se běžně (bez citací = přesnost 0)
Neplatný formát	P2 odpověď bez sekce ZDROJE	Ne	Hodnotí se; zapíše se do validity formátu
Chyba nástroje	„Vyhledávání se nezdařilo“	1× ihned	První pokus i výsledek zvlášť
Limit požadavků	Vyčerpaný denní limit	1× do 24 hodin	První pokus i výsledek zvlášť
Časový limit	Žádná odpověď do 180 sekund	1× ihned	První pokus i výsledek zvlášť
Výpadek produktu	Chyba serveru, stránka nedostupná	1× v rámci 24hodinového okna	První pokus i výsledek zvlášť
Chyba studenta	Vložen špatný prompt, zapnutý hloubkový výzkum	Ano, běh se zahodí	Nepočítá se systému, eviduje se
Chyba evaluace	Špatně zkopírovaná URL do listu	Ne, opraví se záznam	Oprava se zapíše

Každé selhání a každý ruční zásah zapíšeme do sloupců `failure_type`, `retries` a `manual_intervention` v metadatech běhu. Neúspěšný pokus nemazáme ani po úspěšném opakování.

8. Analýza chyb

Analyzujeme 12 případů (zadání vyžaduje 8): alespoň 2 za každý systém, alespoň 3 úspěšné odpovědi a alespoň jeden případ z každého typu okrajové podmínky. Každé selhané dvojici tvrzení–citace přiřadíme jeden hlavní kód chyby.

Kód	Typ chyby	Definice
E1	Vymyšlený zdroj	URL, DOI nebo dokument neexistuje
E2	Nepodporující zdroj	Zdroj existuje, ale tvrzení neobsahuje
E3	Přehnané zobecnění	Zdroj říká méně nebo něco užšího než tvrzení
E4	Záměna citací	Fakt je v jiném citovaném zdroji než v tom, který je u tvrzení
E5	Zkreslené číslo nebo datum	Zdroj uvádí jinou hodnotu, než jakou systém převzal
E6	Zastaralý zdroj	Zdroj neodpovídá aktuálnímu stavu nebo porušuje časový limit
E7	Méně kvalitní zdroj	Systém cituje agregátor nebo diskusi, i když existuje primární zdroj
E8	Obecná citace	Domovská stránka nebo výsledky vyhledávání místo konkrétního dokumentu
E9	Chybějící citace	Faktické tvrzení nemá žádný zdroj
E10	Přijatý chybný předpoklad	Systém předpoklad neopravil a dokladá ho zdroji
E11	Ignorovaný rozpor	Systém uvede jen jednu z protichůdných hodnot

8.a. Záznam analýzy

U každého analyzovaného případu zapíšeme do `analysis/error_analysis.csv`:

- ID případu, systém, podmínku,
- výňatek odpovědi, citaci a hodnocení,
- kód chyby,
- pravděpodobnou příčinu: **vyhledání** (zdroj nenašel), **přiřazení** (našel, ale připojil špatně) nebo **generování** (zdroj měl, ale text zkreslil),
- zda chybu opravila podmínka P3.

Hledáme opakující se vzorce, například zda se E6 soustředí u případů s nedávnou změnou faktu nebo E2 u českých dotazů.

9. Harmonogram a role

Projekt trvá 10 týdnů a má tři brány, za které se nevracíme. Role jsou rozdělené tak, aby autor promptu neviděl testovací sadu.

9.a. Brány

Brána	Co se zmrazí	Kdy
G1	Zmrazení protokolu	Před prvním během
G2	Zmrazení P3	Před otevřením testovací sady
G3	Konec hodnocení	Před výpočtem výsledků

> **Note**
>
> Týdny jsou relativní; tým je přepíše na data semestru. Pevné je jen pořadí: G1 před prvním během, G2 před otevřením testovací sady, G3 před výpočtem výsledků.

9.b. Role

Role	Odpovědnost	Omezení
Koordinátor protokolu	Protokol, metadata běhů, dodržení 72hodinového okna	—
Správce dat	Testovací sada, hash, validace případů, zaslepení anotačního listu	Nesdílí testovací případy s autorem promptu
Autor promptu	P2, kandidáti P3, changelog	Neotevře testovací sadu před zmrazením P3
Analytik	Skripty, bootstrap, grafy, reprodukovatelnost balíčku	—
Hodnotitelé (všichni)	Lidské hodnocení, dvojité hodnocení 25 % odpovědí	Nehodnotí běhy, které sami spouštěli

Ve dvoučlenném týmu spojíme koordinátora se správcem dat a autora promptu s analytikem.

10. Limity a co výsledky neprokážou

Výsledek bude porovnáním pěti produktů na 40 konkrétních dotazech v jednom časovém okně. Nebude to měření schopnosti jazykových modelů ani obecný žebříček.

Limit	Důsledek	Co s tím děláme
Malý vzorek (10 testovacích případů)	Široké intervaly, malé rozdíly nerozlišíme	Velikost efektu a intervaly, doplňkové výsledky z vývoje
Produkty se mění	Model, rozhraní i vyhledávání se mohou změnit během dnů	72hodinové okno, záznam viditelného modelu a data
Web se mění	Zdroj může zmizet nebo se změnit mezi během a hodnocením	Hodnocení do 7 dní od běhu, snímky obrazovky, archivace stránky
Bez parity nástrojů	Rozdíly nelze připsat modelu	Závěry formulujeme jen o produktech
Bezplatná úroveň	Placené verze mohou dopadnout jinak	Uvedeme úroveň a model u každého běhu
Jedno kolo komunikace	Neměříme, jak systém reaguje na doplňující dotazy	Uvedeme jako hranici platnosti
Dotazy sám zvolil tým	Známá fakta může model znát i bez vyhledávání	Hodnotíme citaci, ne jen odpověď; okrajové případy tvoří 45 %
Hodnotitelé jsou studenti	U odborných zdrojů (právo, zdraví) mohou chybovat	Kalibrace, dvojité hodnocení, zlaté zdroje v případu
Dělení na tvrzení je subjektivní	Počet dvojic se může mezi hodnotiteli lišit	Pravidla v rubrice, u P2 a P3 dělí text systém sám
Jen čeština a angličtina, česká IP	Jiné jazyky a regiony mohou dopadnout jinak	Uvedeme jako hranici platnosti

Co výsledky prokázat mohou

Zda se na této sadě a v tomto období liší citační přesnost produktů a zda strukturovaný prompt u jednotlivých produktů pomáhá. Také jaké typy chyb citací se opakují.

Co prokázat nemohou

Který jazykový model je lepší, jak se produkty chovají na jiných typech dotazů a zda rozdíly vydrží po další aktualizaci produktu.

11. Reprodukovatelný balíček

Balíček `czai-citace.zip` obsahuje vše, co jiný student potřebuje ke kontrole a zopakování analýzy. Skripty potřebují jen Python 3.9+ se standardní knihovnou a celý tok je otestovaný na syntetických datech (`bash demo/run_demo.sh`).

Zdrojový kód je dostupný na https://github.com/Nouzl0/ENC-AI-Project.

Požadavek zadání	Soubor v balíčku
1 Výzkumný protokol	tento dokument a `PROTOCOL.md` (zmrazené parametry, brány, hashe, odchylky)
2 Benchmarková data	`data/cases_dev.jsonl`, `cases_val.jsonl`, `cases_test.jsonl` a popis polí v `data/README.md`
3 Sada promptů	`prompts/` (P1, P2, kandidáti P3-A a P3-B, česky i anglicky) a `prompts/CHANGELOG.md`
4 Metadata běhů	`runs/run_plan_*.csv` z `make_run_plan.py`, návod `runs/README.md`
5 Kód a postupy hodnocení	`scripts/validate_cases.py`, `check_citations.py`, `score.py`, rubrika `annotation/rubric.md`
6 Výsledky	`results/` z `score.py`: metriky, intervaly, hypotézy, opakované běhy, užitek, Pareto, shoda
7 Analýza chyb	`analysis/error_analysis_TEMPLATE.csv` a návod
8 Závěrečná zpráva	Sepíše tým po bězích; osnovu dávají sekce tohoto dokumentu

11.a. Postup v příkazech

1. `python3 scripts/validate_cases.py --write-hashes`, pak zapsat hashe do `PROTOCOL.md` (**G1**).
2. `python3 scripts/make_run_plan.py --phase dev`, spustit běhy podle `runs/README.md`.
3. `python3 scripts/check_citations.py --runs runs/run_plan_dev.csv --out-dir annotation/dev`, ohodnotit listy.
4. Stejně fáze `val`, poté vytvořit `prompts/P3_final_*.txt` (**G2**). Skript bez něj fázi `test` nespustí.
5. Fáze `test` a `repeat`, hodnocení s druhým hodnotitelem, vyřešení neshod (**G3**).
6. `python3 scripts/score.py`, pak analýza chyb a závěrečná zpráva.

11.b. Zdroje

- Zadání: CZAI Assignment 1 (PDF od vyučujícího).
- Nastavení produktů (stav k 29. 9. 2026): ChatGPT search, ChatGPT Temporary Chat, Gemini Apps Help, Gemini temporary chats, Claude web search, Claude incognito, Perplexity Pro Search, Perplexity Memory, About Grok.
- API s webovým vyhledáváním: OpenAI web search, Gemini grounding, Anthropic web search tool, xAI web search.

- Referenční zdroje ke každému testovacímu případu jsou v poli `gold_sources` v `data/`, všechny otevřené a ověřené 29. 9. 2026.