Správnost citací AI asistentů s webovým vyhledáváním

Jan Dub[1], **René Mrákava**[1], and **Nikolas Nosál**[1]

[1]Mendelova univerzita v Brně, Provozně ekonomická fakulta

Abstract

Projekt plánuje změřit, jak často citace AI asistentů s webovým vyhledáváním (ChatGPT, Gemini, Claude, Perplexity, Grok) skutečně podporují tvrzení, ke kterým jsou připojeny. Plánujeme porovnání produktů jako celků na alespoň 40 faktických rešeršních dotazech v češtině a angličtině a ve třech promptových podmínkách. Hlavní metrikou je citační přesnost na úrovni tvrzení, doplněná úplností citací a správností odpovědi.

Keywords správnost citací, atribuce zdrojů, generativní vyhledávače, jazykové modely s vyhledáváním, halucinace

1. Úvod a výzkumná otázka

Projekt plánuje porovnání pěti produktů s webovým vyhledáváním ve směru B: správnost a úplnost citací na faktických CZ/EN rešeršních úlohách z pěti oblastí. Měřením je podpora tvrzení skutečně přiřazeným zdrojem, nikoli čistá schopnost samotného modelu. Existuje 20 dev + 10 val návrhů; nový nezávislý holdout ≥10 a finální experiment zatím nejsou dokončené.

1.a. Výzkumná otázka

Jak často citovaný zdroj skutečně podporuje tvrzení u ChatGPT, Gemini, Claude, Perplexity a Groku na definovaném mixu ≥40 úloh a jak tuto atribuci mění společný P1, strukturovaný P2 a obecně optimalizovaný P3? Praktickým významem je ověřitelnost citací při rešerši. Závěry se omezí na měřené produkty, účty, režimy, úlohy, jazyky a období.

Hlavní metrika je průměr explicitní citační přesnosti po odpovědích prvního běhu, se stejnými vahami úloh. Vedlejší metriky jsou úplnost citací celé odpovědi a správnost proti RF/RC. S2 neznamená pravdivost.

1.b. Předem definované hypotézy

H1: Bodový odhad přesnosti předem zvoleného focus produktu (výchozí Perplexity) v P2 minus průměr ostatních zahrnutých produktů je ≥0,10 a dolní mez 95% párového bootstrapového CI je >0. Navrhovaný mechanismus je hypoteticky lepší vazba retrievalu a citovaných pasáží; není zde vydáván za ověřenou vlastnost produktu.

H2: Bodový odhad P2 minus P1, průměrovaný přes zahrnuté produkty, je ≥0,05, dolní mez CI je >0 a kladný odhad má ≥4/5 produktů (≥3/4 při předem zdůvodněném

ENC-AI Project

Published Oct 12, 2026

Acknowledgements
Mendelova univerzita v Brně, Provozně ekonomická fakulta. Všichni autoři přispěli k vypracování zadání.

Data Availability
Protokol, data, prompty, skripty a testy jsou dostupné na https://github.com/Nouzl0/ENC-AI-Project.

čtyřproduktovém návrhu). Hypotetickým mechanismem jsou instrukce přiřadit důkaz a přiznat nejistotu.

Obě hypotézy se vyhodnotí **výhradně na novém testu po G3**. Dev/val nejsou potvrzující test a nepřidávají se do jeho n. Uvedená pravidla podpory praktického odhadu nejsou důkazem populačního efektu ≥margin. Silnější diagnostika `ci_above_margin` se uvede odděleně; společná chybovost H1/H2 není garantována. P3 a další žebříčky jsou explorační.

1.c. Alternativní vysvětlení

Alternativa	Kontrola v reportu
A1: méně tvrzení místo lepší atribuce	Úplnost, RF pokrytí, počet tvrzení/citací a deskriptivní Spearman
A2: zdrojová dostupnost, jazyk a doména	NA a členění podle jazyka/domény; CZ/EN nejsou párované překlady
A3: změna formátu atribuce při P2	Podíl explicitně citovaných odpovědí a podmíněná přesnost s n

Korelace ani lepší P3 odpověď samy neprokazují příčinu. Účelový malý vzorek, rozdílné účty a skryté nastavení produktů omezují interpretaci. Přesná metodika a pravidla zmrazení jsou v `PROTOCOL.md`.

2. Porovnávané systémy a přístup k nástrojům

Volíme návrh podle schopností produktu: každý asistent používá své běžné webové vyhledávání a výsledky prezentujeme výslovně jako **porovnání produktů**. Paritu nástrojů ve spotřebitelských rozhraních zajistit nelze, protože každý produkt má vlastní vyhledávač, index a zobrazení citací. Claude Code nezahrnujeme, protože jde o nástroj pro programování.

Systém	Jak zajistit vyhledávání	Režim bez paměti	Vyloučený režim
ChatGPT	Vynutit nástrojem Search (menu nástrojů nebo „/“)	Temporary chat, varianta Unpersonalized	Deep research
Gemini	Automaticky, přepínač není zdokumentován	Temporary chat (osobní účet)	Deep Research
Claude	Přepínač Web search, v novém rozhraní automaticky	Incognito chat a smazané preference a styly profilu	Research
Perplexity	Vždy, režim Search	Incognito	Research, Labs
Grok	Automaticky (web a X)	Private Chat	DeepSearch

> **Note**
>
> Nastavení odpovídá nápovědě výrobců k 29. 9. 2026. První den běhů ho ověříme snímkem obrazovky, protože se rozhraní mění.

2.a. Pravidla běhu

1. Každý dotaz začíná v novém chatu v režimu bez paměti, bez vlastních instrukcí, bia a stylů. To je plán analytické konfigurace. Nový pilot používá existující přihlášené účty v Avastu; jejich skutečná úroveň a nastavení jsou evidované odchylky.
2. Před-G1 revize používá podle pokynu uživatele existující účty v Avastu: Gemini Plus, Perplexity Free, ostatní tarify výslovně unknown. Rozdílné účty se zaznamenají jako omezení. Pilotní viditelné modely: ChatGPT GPT-6 Střední, Gemini 3.6 Flash, Claude Opus 5.5 Medium, Grok Fast, Perplexity výchozí model bez názvu. Definitivní nastavení a přístup všech produktů se doloží před G1.
3. Použijeme stejný prohlížeč, českou síť a češtinu rozhraní. Pořadí systémů pro každý případ losuje skript (seed 2026).
4. Jeden případ projde všemi pěti systémy během 24 hodin, celou testovací sadu zvládneme do 72 hodin.
5. Platí jedno kolo komunikace. Pokud se systém doptá, odpovíme větou „Pokračujte podle svého nejlepšího úsudku.“ a kolo navíc zaznamenáme.
6. Uložíme text odpovědi, všechny URL citací (z panelu zdrojů nebo exportu), snímek obrazovky a odkaz na sdílení.

2.b. Co lze od čeho oddělit

Zdroj výkonnosti	Oddělíme ho?	Jak
Vliv promptu	Ano	Stejný systém v podmínkách P1, P2 a P3
Vliv nástrojů	Částečně	Evidujeme, zda proběhlo vyhledávání a kolik zdrojů systém zobrazil
Schopnost modelu	Ne	Ve spotřebitelském rozhraní model nelze odpojit od vyhledávání
Vliv produktu	Ne	Rozhraní, bezpečnostní vrstva a vyhledávač tvoří celek

2.c. Metadata běhů

Metadata každého běhu zapisujeme do `runs/run_plan_<fáze>.csv`:

- systém, viditelný název modelu, rozhraní a úroveň předplatného,
- datum a čas (Europe/Prague),
- podmínku a verzi promptu s hashem SHA-256 a systémovou instrukci („výchozí, neviditelná“),
- oprávnění nástrojů, kontextové soubory (žádné), teplotu a délku výstupu („výchozí, nenastavitelné“),
- počet kol, počet zobrazených vyhledávání, latenci, náklady,
- opakování, typ selhání a ruční zásahy.

2.d. Volitelné rozšíření: API

Stejnou sadu lze spustit přes API s nástroji pro webové vyhledávání (OpenAI, Gemini, Anthropic, xAI). API dovolí nastavit teplotu a délku výstupu a vrací strukturovaná metadata citací. Výsledky API bychom vykazovali odděleně jako druhou vrstvu (dvouvrstvý návrh) a neslévali je s výsledky produktů.

3. Testovací sada

Existuje **20 dev a 10 val případů** a nově **10 soukromých AI kandidátů** připravených pro správce Reného. Návrh obsahuje 40 různých úloh; schválený nezávisle lidsky ověřený holdout a dokončená evidence všech RF/OF zatím chybí. Historické veřejné CIT-031–040 nejsou skrytý test. Validátor ověřuje schéma a stratifikaci, nikoli pravdivost referencí. Datum v návrhu reference není důkaz dokončené nezávislé kontroly.

Vlastnost	Vývoj: skutečnost (20)	Validace: skutečnost (10)	Test: soukromý návrh (10)
Oblasti: věda a zdraví / právo / IT / ekonomika / historie a kultura	4 / 4 / 4 / 4 / 4	2 / 2 / 2 / 2 / 2	2 / 2 / 2 / 2 / 2
Jazyk: CZ / EN / CZ+EN	10 / 9 / 1	5 / 4 / 1	4 / 5 / 1
Typ: fakt / primární zdroj / syntéza	10 / 6 / 4	3 / 4 / 3	5 / 3 / 2
Obtížnost: snadná / střední / těžká	3 / 11 / 6	4 / 4 / 2	1 / 6 / 3
Okrajové případy	9 (45 %)	4 (40 %)	4 (40 %)

Table 1: Složení testovací sady

Soukromý návrh splňuje kvóty `data/holdout_blueprint.json`, schéma i kontrolu překryvů. Kritický AI reviewer neidentifikoval sémantickou duplicitu s veřejnými 40 případy. To není lidské schválení ani důkaz nepřítomnosti tréninkové kontaminace. Následující příklady a počty jsou pouze z veřejných dev/val; obsah testu se před G2 nezveřejňuje.

3.a. Okrajové případy

Okrajový případ	Dev + val: skutečný počet	Příklad z vývojové sady	Co je správné chování
Nepravdivý předpoklad	2	„Proč musí mít kandidát do Senátu ČR alespoň 35 let?“	Opravit na 40 let, čl. 19 odst. 2 Ústavy
Protichůdné zdroje	2	Nadmořská výška Sněžky (1602 vs. 1603 m)	Uvést obě hodnoty a důvod rozdílu

Okrajový případ	Dev + val: skutečný počet	Příklad z vývojové sady	Co je správné chování
Chybějící informace	3	Přesné datum narození Shakespeara	RF: přiznat, že přesné datum není známo; křest je pouze OF
Nejednoznačné zadání	2	„Kdy vznikla Česká republika?“	RF: samostatná ČR 1. 1. 1993; 1969/1990 jsou pouze OF
Časové omezení	1	Aktuální sazba ECB, jen zdroje z posledních 30 dní	Uvést hodnotu, datum účinnosti a datum zdroje
Nedávná změna faktu	1	Podpora Windows 10 a program ESU	Ověřit stav pro daný produkt a datum
Kombinace češtiny a angličtiny	2	Co znamená SBOM a který exekutivní příkaz ho prosadil	Odpovědět česky, termíny ponechat

3.b. Schéma případu

Schéma obsahuje všech 13 polí zadání: `task_id`, `capability`, `task_type`, `difficulty`, `language`, `development_validation_test_split`, `user_prompt`, `context_or_files`, `expected_properties`, `reference_answer_or_tests`, `edge_case_type`, `evaluation_method`, `source_or_provenance`. V2 navíc odděluje `required_facts` (RF), `optional_facts` (OF) a `required_constraints` (RC). `key_facts` je alias RF. Vynechání OF se netrestá.

3.c. Ochrana testovací sady

- Nový návrh vznikl přímo mimo Git pro správce Reného; čeká na jeho kontrolu. Historické zveřejněné kandidáty nelze použít jako skrytý test ani po přejmenování.
- Autor promptu P3 soubor neotevře, dokud není P3 zmrazený.
- Hash SHA-256 souboru zapíšeme do protokolu před prvním během. Skript `validate_cases.py` hlídá, aby se test nepřekrýval s vývojem (podobnost otázek nad 0,5).

Navedení v otázce

Část dev případů s protichůdnými zdroji rozpor v otázce nenaznačuje. U soukromého návrhu jsou doložené agregované počty; lidské potvrzení významu okrajových případů a referencí zůstává součástí G1.

Dynamické případy

> RUN_DAY reference se doloží zvlášť pro každý UTC den dokončených běhů, se skutečnou hodnotou, locatorem, časem a snapshotem/SHA-256. Původní zmrazená reference se nepřepisuje.

3.d. Etika dat

Všechny dotazy jsou syntetické a vytvořil je tým. Ptáme se jen na veřejně dostupná fakta, bez osobních údajů, důvěrných dat a autorsky chráněných textů. Ke každému případu uvádíme původ a datum ověření.

4. Kontrola referencí před G1

Datum kontroly: 12. 10. 2026. Read-only AI reviewer prošel všech 30 veřejných dev/val případů; operátor zkontroloval významné nálezy. Tato kontrola připravuje podklady pro nezávislého lidského ověřovatele. Není lidskou verifikací, ratingem produktových odpovědí ani úplným `source_evidence.csv` se snapshoty všech RF/OF.

Úloha	Přečtený podklad a locator	Zjištění / zbývající mezera
CIT-001	Originální článek, Europe PMC XML, Abstract Results a Table 2	95 %, 95% credible interval 90,3–97,6. NEJM přímo vracel 403.
CIT-002	WHO, Strong/Conditional recommendation	Volné cukry <10 % energie; <5 % podmíněné doporučení; guideline 2015.
CIT-003	NNDC ENSDF, parent 14C; Stuiver–Polach, § 3	5 700 ±30 let; historický konsenzus 5 730 ±40 a konvenční Libbyho hodnota 5 568 se nesmějí zaměnit.
CIT-004	Zeměměřický úřad, odstavec měření a staré kóty	1 603,296 m; 1 602 je zaokrouhlená kóta jiného trigonometrického bodu 1 602,02 m. Měření je z 2014.
CIT-005	MMR, úvod; text zákona, § 334a–335	Běžné stavby od 1. 7. 2024; formální účinnost a přechodné režimy odlišeny.
CIT-006	e-Sbírka, § 230 odst. 1	Přímé otevření neposkytlo čitelný text. Současná dvouletá sazba je zatím jen indexovaný podklad. Starý policejní PDF má jinou sazbu.
CIT-007	GFŘ PDF, § 2.2, s. 3–4	RF jídlo 12 % potvrzen. OF nápoje opraveno o výjimky; historické OF „předtím 10 %“ ještě samostatně ověřit.
CIT-008	Ústava, PSP, čl. 19 odst. 2	Věk 40 let; premisa 35 je chybná.
CIT-009	NVD API, cvssMetricV31, Primary NVD	CVSS 3.1: 10.0, CRITICAL.
CIT-010	Microsoft ESU, úvod a How to get Windows 10 ESU	Konec podpory 14. 10. 2025, nynější spotřebitelské ESU do 12. 10. 2027. Historické OF původně 13. 10. 2026 zbývá ověřit; blog vracel 403.
CIT-011	UCLA / Kleinrock, úvod a IMP log	„lo“, 29. 10. 1969, UCLA arrow.r SRI.

Úloha	Přečtený podklad a locator	Zjištění / zbývající mezera
CIT-012	GovInfo EO, § 4; NTIA, úvod	SBOM definice, EO 14028 z 12. 5. 2021; NTIA minimum elements 12. 7. 2021.
CIT-013	ČSÚ první výsledky, první dva odstavce	10 524 167; půlnoc 26./27. 3. 2021. Stránka má rozpor textového roku vydání a metadat, nikoli počtu.
CIT-014	Eurostat původní release; aktuální API, rok 2023	Původně 24,5 %, databáze aktualizovaná 15. 9. 2026: 24,579 %, zaokrouhleně 24,6 %. Hodnotit správnou verzi, ne trestat doloženou revizi.
CIT-015	ECB Bulletin 6/2026, Summary arrow.r Monetary policy decisions a metadata	MRO 2,65 % od 16. 9.; publikace 24. 9. splňuje 30 dnů k datu kontroly. Zpráva 10. 9. již nikoli.
CIT-016	Bitslog původní analýza, metodické předpoklady	Odhad těžby nedokazuje přesné současné vlastnictví BTC. Celý OF rozsah 0,6–1,1 milionu nebyl ověřen, BitMEX vracel 404.
CIT-017	Historie UK, rok 1348	7. 4. 1348, Karel IV.
CIT-018	Archiv Národního divadla, světová premiéra	29. 10. 1787, Stavovské divadlo; historický název Nosticovo tento odstavec samostatně nepotvrdil.
CIT-019	MZV; PSP federace, Úvod	Samostatný stát 1. 1. 1993, federace od 1. 1. 1969. Přesný den přejmenování 6. 3. 1990 dosud pouze index e-Sbírky.
CIT-020	Shakespeare Birthplace Trust, Parish Register	Přesné narození není zaznamenáno; křest 26. 4. 1564, tradice narozenin 23. 4.
CIT-021	Nobel Foundation, Prize motivation	Zákon fotoelektrického jevu, cena za 1921, převzetí 1922.
CIT-022	EHT release, úvod	EHT, M87*, 10. 4. 2019.
CIT-023	EUR-Lex, čl. 83 odst. 5	Limit doplněn o podnik a předchozí finanční rok. Přímé HTML/PDF končilo robot challenge; nejde o dokončené primární ověření.

Úloha	Přečtený podklad a locator	Zjištění / zbývající mezera
CIT-024	Evropská komise, 2030 climate target	Alespoň −55 % čistých emisí proti 1990. OF čl. 4 odst. 1 přímo v EUR-Lex neotevřen.
CIT-025	Originální arXiv, metadata a abstrakt	Název, Patrick Lewis et al., NeurIPS 2020, arXiv:2005.11401. Absolutní historická priorita termínu samostatně neprokázána.
CIT-026	RFC Editor, hlavička	RFC 9114, červen 2022.
CIT-027	ČSÚ srpen, Míra nezaměstnanosti; ÚP září, odrážky 1–2	ČSÚ VŠPS 15–64 očištěně 3,4 % za srpen; ÚP PNO 5,0 % za září. ČSÚ 15–74 varianta 3,2 %. Čísla/období/definice odlišit.
CIT-028	MPSV, titul a mechanismus	20 800 Kč měsíčně pro 2025.
CIT-029	UK, historický odstavec	Stavba 1357–1402. RF „přesnou cenu v dnešních Kč nelze určit“ není přímo podpořen zdrojem; potřebuje přezkoumání metodiky převodu a nákladů.
CIT-030	Nobel Foundation, laureát	Jaroslav Seifert, 1984.

Následná kontrola operátora doplnila dvě historické mezery: Finanční správa, 6. 6. 2023, s. 2, dokládá 10 % pro stravování; Microsoft News Center, 30. 6. 2025, první varianta spotřebitelského ESU, dokládá původní konec 13. 10. 2026. Historický konsenzus uhlíku-14 5 730 ±40 let dokládá také Radiocarbon, Notice to Readers, PDF s. 3; tento přesný údaj neodvozujeme jen ze Stuiver–Polach.

Před podpisem G1 je třeba vyřešit ostatní uvedené mezery a získat lidskou kontrolu každého RF i OF s konkrétní hodnotou, locatorem, datem a soukromým snapshotem/hash. Žádné přístupové selhání není důkazem neexistence zdroje. Dynamické reference se navíc ověřují podle UTC dne každého analytického běhu.

5. Podmínky promptů

Všechny tři podmínky dostanou stejnou otázku a liší se jen obalem kolem ní. Anglické případy používají překlad stejného textu, všechny verze jsou v `prompts/`. Systémově specifické úpravy nepovolujeme (cíl je 0).

5.a. P1 – společná výchozí podmínka

Šablona ze zadání a jedna věta o formátu:

```
Vyřešte níže uvedenou úlohu. Odpovězte pouze v požadovaném formátu.

Úloha:
{user_prompt}
Formát: stručná odpověď s odkazy na použité zdroje (URL).
```

5.b. P2 – strukturovaný prompt

Verze 1.0, napsána před prvním během:

```
Jste pečlivý rešeršní asistent. Každé tvrzení dokládáte zdrojem, který
jste v této konverzaci skutečně otevřeli.

Cíl: odpovězte přesně a stručně na otázku tak, aby si čtenář mohl každé
tvrzení ověřit.

Otázka:
{user_prompt}

Pravidla:
1. Vyhledejte informace na webu. Necitujte zdroj, který jste neotevřeli,
a nevymýšlejte URL.
2. Za každým faktickým tvrzením (číslo, datum, jméno, definice) uveďte
odkaz na zdroj ve tvaru [1], [2].
3. Citujte konkrétní stránku nebo dokument, ne domovskou stránku ani
výsledky vyhledávání.
4. Upřednostňujte primární a oficiální zdroje (zákon, úřad, původní
studie, standard).
5. Pokud otázka obsahuje chybný předpoklad, nejprve ho opravte.
6. Pokud se zdroje liší, uveďte obě hodnoty, každou s vlastním zdrojem,
a vysvětlete rozdíl.
7. Pokud otázka omezuje stáří zdrojů, použijte jen zdroje, které omezení
splňují, a uveďte jejich datum.
8. Pokud spolehlivou odpověď nenajdete, napište to. Nehádejte.

Formát výstupu:
ODPOVĚĎ: 1–3 věty s přímou odpovědí.
TVRZENÍ:
T1: <jedno tvrzení> [n]
T2: <jedno tvrzení> [n]
ZDROJE:
[1] <název> — <vydavatel> — <datum vydání nebo „neuvedeno"> — <úplná
URL>
JISTOTA: vysoká / střední / nízká — jedna věta proč.
```

5.c. P3 – optimalizovaný prompt

P3 vznikne z P2 jen na základě vývojové a validační sady:

1. Po běhu P2 na vývojové sadě sečteme typy chyb (taxonomie viz \#error-analysis). Úprava je povolená jen proti typu chyby, který se objevil alespoň třikrát.
2. Před G1 zvolíme jednoho nebo oba kandidáty. Předběžný **P3-A** přidává úryvek ≤25 slov ke tvrzení; **P3-B** navíc kontrolu před odesláním. Jde o hypotézy, konečné změny musí doložit alespoň tři chybné dev odpovědi s ID a kódem chyby.
3. Proběhne jedna plánovaná validace P2 a kandidátů. Výběr se přepočte v plné přesnosti z archivovaného `scoring_inputs.json`. Při rozdílu <0,02 rozhodne kratší průměrná délka CZ/EN šablony včetně whitespace, při shodě P3A.
4. Vítěze přesně zkopírujeme v CZ/EN do P3_final, zaznamenáme důkazy/hashe a podepíšeme G2 před otevřením testu. I při nezlepšení P2 se vybere měřený kandidát a neúspěch se přizná. **Po validaci není další ladění povolené.** Změny patří do `prompts/CHANGELOG.md`.

> **Warning**
>
> P3 nesmí obsahovat pokyny pro konkrétní případy ani informace, které by prozradily odpovědi.

5.d. Přenositelnost

Přenositelnost vykazujeme pro P2 i P3:

- průměrné zlepšení oproti P1,
- zlepšení podle jednotlivých systémů a na testovací sadě,
- délku promptu ve znacích,
- počet systémově specifických úprav,
- dodatečná kola komunikace.
- dodatečná viditelná volání nástrojů a jejich pokrytí.

Prompt, který jednomu systému pomůže a ostatním uškodí, vykazujeme jako platný výsledek, ne jako lepší obecný prompt.

6. Metriky

Hlavní metrikou je citační přesnost na úrovni tvrzení. Vedlejší metriky jsou úplnost citací a správnost odpovědi. Všechny definice a váhy platí od zmrazení protokolu, před prvním testovacím během.

6.a. Jednotky hodnocení

Tvrzení Atomický faktický výrok: číslo, datum, jméno, definice nebo vztah. Složené věty dělíme a významové duplicity konzervativně sjednocujeme. Hodnotitel kontroluje všechna faktická tvrzení celé odpovědi, včetně ODPOVĚĎ, nikoli jen TVRZENÍ. Limit osmi tvrzení neplatí. Úryvky P3 jsou důkaz, nikoli další tvrzení.

Dvojice tvrzení–citace Tvrzení a zdroj, který k němu systém skutečně připojil. Nepřiřazený seznam zdrojů (*) je pouze diagnostika `unlinked_support`; nepočítá se do hlavní přesnosti, úplnosti, RF pokrytí ani hlavní kappy. Hodnotitel atribuci nedoplňuje.

Hodnocení dvojice **S2** plně podpořeno, **S1** částečně podpořeno, **S0** nepodpořeno nebo v rozporu, **NA** zdroj nedostupný, **FAB** zdroj neexistuje.

6.b. Hlavní metrika – citační přesnost

Pro odpověď a počítáme podíl **explicitních** S2 dvojic ze všech explicitních dvojic včetně NA/FAB. Agregace je průměr přes úlohy prvního běhu se stejnými vahami. Opakování P2 se vykazují zvlášť a nezvyšují počet nezávislých úloh.

$$\text{Přesnost}_a = \frac{|\ \text{explicitní S2 dvojice odpovědi } a\ |}{|\ \text{všechny explicitní dvojice odpovědi } a\ |} \tag{1}$$

NA a FAB zůstávají ve jmenovateli. Bez explicitních citací a při konečném provozním selhání je přesnost nula. S2 měří podporu zdrojem, nikoli pravdivost tvrzení.

6.c. Vedlejší metriky

Úplnost citací měří, kolik tvrzení je podloženo alespoň jednou citací S2. Tvrzení bez citace má hodnotu 0.

$$\text{Úplnost}_a = \frac{|\ \text{tvrzení odpovědi } a\ \text{ s alespoň jednou citací S2}|}{|\ \text{všechna hodnocená tvrzení odpovědi } a\ |} \tag{2}$$

Správnost odpovědi je podíl odpovědí se skóre 2 na škále 0–2. Skóre 2 vyžaduje všechny RF a splněné RC; vynechání OF se netrestá, dobrovolně uvedená chybná fakta se hodnotí. U chybných předpokladů a chybějících informací platí pravidla rubriky.

6.d. Diagnostické metriky

Diagnostická metrika	Definice	Proč ji sledujeme
Míra neexistujících zdrojů	Podíl citací s hodnocením FAB	Halucinace citací
Míra nedostupných zdrojů	Podíl citací s hodnocením NA	Kontrola alternativy A2
Kvalita zdrojů	Podíl citací na primární nebo oficiální zdroj	Upřednostnění důvěryhodných zdrojů

Diagnostická metrika	Definice	Proč ji sledujeme
Dodržení časového omezení	Podíl citací, které splňují limit stáří	Případy s časovým omezením
Vhodné přiznání nejistoty	Podíl odpovědí na chybějící nebo nejednoznačné dotazy, které nejistotu přiznají	Práce s nejistotou
Tvrzení a citace na odpověď	Průměrný počet	Kontrola alternativy A1
Nepřiřazené citace	Podíl citací uvedených jen souhrnně	Granularita citování

6.e. Provozní metriky

Medián a p90 první i celkové latence, první/konečná úspěšnost, retry, kola a viditelná volání nástrojů. Mezní poplatky, předplatné a lidská práce se vykazují odděleně. Neznámé tokeny, kredity a ceny nejsou nula. Čas anotace `check_minutes` není uživatelský čas oprav.

Explorační `annotation_effort_index` má předem stanovené váhy. L_{norm} a T_{norm} jsou mediány latence a anotace dělené maximem příslušných mediánů mezi produkty v dané sadě a podmínce. Chybějící čas nezíská nulovou penalizaci. Nejde o obecný užitek; Pareto-fronta používá přesnost a latenci.

$$\text{Index anotačního úsilí} = \text{Přesnost} - 0,1 \cdot L_{\text{norm}} - 0,1 \cdot T_{\text{norm}} \tag{3}$$

Bootstrap používá celé `task_id`, 10 000 převzorkování a seed 2026. Konstantní interval [p,p] není nulová populační nejistota; vykazují se diagnostické příznaky a n. Binární podíly mají Wilsonovy intervaly. U source/time/ack se hlásí `checked/expected`; unknown není pozitivní kontrola. H2 doplní podíl explicitně citovaných odpovědí a jejich podmíněná přesnost s n, aby se odlišila změna formátu atribuce.

7. Automatické kontroly a lidské hodnocení

`check_citations.py` parsuje citace, uchovává původní URL a připravuje zaslepené podklady. HTTP dostupnost, přesměrování, obecnost URL, shoda entit, datum publikace a formát jsou diagnostiky pro správce. **Oba nezávislí hodnotitelé dostávají stejné podklady bez automatických nápověd.** Automatika nepředvyplňuje jejich ratingy. Samotná HTTP chyba neprokazuje neexistenci zdroje; paywall není automaticky nepodpořené tvrzení.

7.a. Rubrika a nezávislost

Rating	Pravidlo
S2	Zdroj plně podporuje atomické tvrzení v uvedené přesnosti
S1	Podporuje jen část nebo užší tvrzení
S0	Tvrzení neobsahuje nebo mu odporuje
NA	Obsah se nepodařilo přečíst; rozhodnutí má zdrojovou evidenci
FAB	Neexistence zdroje je doložená podle rubriky

Úplná pravidla a kotvy všech ratingů i správnosti 0/1/2 jsou v `annotation/rubric.md` a `annotation/calibration.md`. Skóre správnosti 2 vyžaduje správné RF a splněné RC; vynechání OF se netrestá. Segmentace zahrnuje celou odpověď, bez limitu osmi tvrzení.

Uživatel 12. 10. 2026 určil **Reného Mrákavu a Jana Duba jako plánované lidské hodnotitele**. To potvrzuje role, nikoli provedení hodnocení. Jejich samostatné ratingy a kalibrace zatím nejsou k dispozici. Operátor nesmí hodnotit vlastní běhy.

7.b. Postup

1. Před G1 oba lidé samostatně projdou offline kotvy a skutečný pilot CIT-001/CIT-020. Kalibrace a případné změny rubriky se archivují.
2. Správce exportuje zaslepené listy v náhodném pořadí, seed 2026. Identita produktu/podmínka jsou skryté, formát je však může prozradit. Původní text, atribuce a URL se při normalizaci neopravují.
3. Hodnotitel 1 posoudí všechny dokončené odpovědi. Hodnotitel 2 posoudí předem náhodně vybraných **≥25 % v každém stratu fáze × produkt × podmínka**, se zaokrouhlením nahoru. Zadání vyžaduje nejméně 20 %.
4. Původní nezávislé listy zůstanou zachované před diskusí. Cohenova kappa S2/ostatní, surová shoda a n se počítají z nich, nikoli z konsenzu. Při konstantní kategorii je kappa nedefinovaná; segmentace se posuzuje zvlášť.
5. Každá neshoda a každá změna final oproti raw1 se zapíše do auditu. Nevyřešenou neshodu rozhodne nezávislý třetí člověk. Slabá shoda se neskrývá selektivním přehodnocením ani přepisem původních ratingů.
6. G3 vyžaduje úplnou matici, ratingy, source/RUN_DAY důkazy, audit a skutečný lidský podpis. Poté lze spustit `score.py --final`.

LLM návrh segmentace nebo ratingu musí být oddělený a označený jako strojový. Svolení týmu není důkaz dvou nezávislých lidských kontrol. Pokud se LLM skutečně

použije jako hodnotitel, platí požadavky zadání na identifikaci modelu, lidskou kalibraci, shodu a kontrolu hodnoticích zkreslení.

8. Plán běhů a nejistota

Výchozí plán má **500 analytických + 10 pilotních odpovědí navíc**. P2 na předem vybraných testových úlohách spouštíme třikrát. Dev se po G1 sbírá znovu; pilot se do analytického dev nepřebírá.

Fáze	Sada	Podmínky	Běhy	Odpovědí (× 5 systémů)
1 Vývoj	vývojová (20)	P2	1	100
2 Validace	validační (10)	P2, P3-A, P3-B	1	150
3 Test	testovací (10)	P1, P2, P3	1	150
4 Opakování	testovací (10)	P2	2 další	100
			Celkem	**500**

Hrubý odhad podle protokolu je 99,7 h včetně 140 druhých hodnocení (10 min na běh a první anotaci, 7 min na druhou). Není to naměřený čas; navíc jsou pilot, reference, audit, analýza, zpráva a čekání na limity.

Úsporná varianta zachová všech pět produktů: jeden P3 kandidát a pět repeat úloh, 400 + 10 běhů, 115 druhých hodnocení a odhad 80,1 h. Čtyřproduktová varianta 320 + 8 je možná pouze při předem doložené nedostupnosti/nevhodnosti pátého, nikoli kvůli úspoře práce; odhad 64,1 h. Varianta a repeat ID se určí před G1, nikdy podle výsledků.

Volitelné rozšíření před G1: P1 na dev (+100) umožní pouze explorační srovnání. Dev/val se nepřidávají do potvrzujícího testu H2, který používá výhradně nový holdout.

8.a. Metody nejistoty

- **Klastrový bootstrap podle případů:** 10 000 převzorkování testovacích případů s vracením (seed 2026) a percentilový 95% interval. Dvojice tvrzení–citace nejsou nezávislé, proto převzorkováváme celé případy.
- **Párový bootstrap rozdílů** pro H1 (Perplexity minus průměr ostatních) a H2 (P2 minus P1). Všechny systémy řeší stejné případy, takže párování odstraní rozptyl obtížnosti případů.
- **Wilsonův 95% interval** pro binární podíly na úrovni odpovědi, například podíl správných odpovědí nebo odpovědí s alespoň jednou FAB citací.
- **Variabilita mezi běhy:** směrodatná odchylka přesnosti přes tři běhy P2 a podíl případů, kde se správnost odpovědi mezi běhy změní.
- **Shoda hodnotitelů:** Cohenova kappa a procento shody (viz Rubrika a nezávislost).

Interpretace

S 10 testovacími případy budou intervaly široké a rozdíly pod zhruba 15 procentních bodů pravděpodobně nepůjde rozlišit. Proto uvádíme velikost efektu, interval a praktický význam, ne jen „signifikanci“.

> Výsledky P2 z vývojové a validační sady uvedeme jako doplňkové, protože P2 na nich laděný nebyl. U P3 platí jen výsledek z testovací sady.

8.b. Selhání a opakování

Neúspěšný běh je součástí dat. Opakování povolujeme jen u selhání mimo model a vždy vykazujeme úspěšnost na první pokus i po opakování.

Typ selhání	Příklad	Opakování	Jak se počítá
Výstup modelu	Odmítnutí, odpověď bez citací, halucinace	Ne	Hodnotí se běžně (bez citací = přesnost 0)
Neplatný formát	P2 odpověď bez sekce ZDROJE	Ne	Hodnotí se; zapíše se do validity formátu
Chyba nástroje	„Vyhledávání se nezdařilo“	1× ihned	První pokus i výsledek zvlášť
Limit požadavků	Vyčerpaný denní limit	1× do 24 hodin	První pokus i výsledek zvlášť
Časový limit	Žádná odpověď do 180 sekund	1× ihned	První pokus i výsledek zvlášť
Výpadek produktu	Chyba serveru, stránka nedostupná	1× v rámci 24hodinového okna	První pokus i výsledek zvlášť
Chyba studenta	Vložen špatný prompt, zapnutý hloubkový výzkum	Svázaná náhrada	Původní excluded řádek a důkaz zůstávají
Chyba evaluace	Špatně zkopírovaná URL do listu	Ne, opraví se záznam	Oprava se zapíše

Každé selhání a každý ruční zásah zapíšeme do sloupců `failure_type`, `retries` a `manual_intervention` v metadatech běhu. Neúspěšný pokus nemazáme ani po úspěšném opakování.

Úplné příkazy s manifesty a soukromými cestami jsou v `HANDOFF.md`. Konstantní bootstrapový CI není nulová populační nejistota. Testové úlohy napříč systémy/podmínkami mají okno 24 h, test 72 h a repeat následujících 72 h; zdrojové ratingy do 7 dní. Odchylky a jejich dopad se zaznamenávají.

9. Výsledky skutečného pilotu

Sběr z 12. 10. 2026 obsahuje **10 skutečných odpovědí na 2 unikátní úlohy**: 2 z původního anonymního pilotu a 8 z nového sběru v Avast Secure Browser 153. Originální odpovědi, raw HTML/texty, metadata, snímky a SHA-256 jsou exportovány v `runs/pilot-2026-10-12/`. Obě kolekce se uchovávají odděleně; nesléváme je do skóre. Souhrn řádků je v `results/pilot/run_summary.csv`. Část původních snímků zachytila jen aktuální viewport. Dodatečné zachycení je odlišené časem a názvem; některé výřezy stále nejsou úplné. Raw text/HTML a skutečné zdrojové karusely zůstávají autoritativním obsahem, snímek není sám úplným dokladem.

Produkt	Nový CIT-001 / P2	Nový CIT-020 / P2	Skutečně viditelný model / tarif
ChatGPT	Odpověď uložena	Odpověď uložena	GPT-6, Střední; tarif unknown
Gemini	Odpověď uložena	Odpověď uložena	3.6 Flash; Plus
Grok	Původní požadavek pokračoval po přístupovém ověření, odpověď uložena	Odpověď uložena	Fast; podkladový model a tarif unknown
Perplexity	Odpověď uložena	Odpověď uložena	Výchozí model bez zobrazeného názvu; Free
Claude	Odeslaný pokus skončil limitem, bez odpovědi	Zatím neodesláno kvůli známému limitu	Opus 5.5 Medium; tarif unknown

Claude hlásil obnovení limitu 13. 10. v 19:00 a sdílení limitů s Claude Code. Pokus je uchován v auditu, není kvalitativně hodnocen jako odpověď modelu. Původní anonymní pilot navíc obsahuje odpovědi ChatGPT a Perplexity na CIT-001; jejich raw/normalizované texty a snímky byly ověřeny po bytech.

9.0.i. *Provozní výsledky a jejich meze:*

Nový plán má 10 řádků: 8 completed, 1 failed (rate limit), 1 planned. Nevyplněný řádek není selhání. Nebyla provedena žádná regenerace věcně chybné odpovědi ani náhrada neúspěšného pokusu lepším textem. Grok pokračoval v původním požadavku, nikoli v novém retry.

Většina uložených intervalů zahrnuje prodlevu zachycení nebo opravu pozorovacího nástroje, proto jsou označené jako horní meze, nikoli přesná generační latence. U CIT-020 bylo dokončení Grok pozorováno po 19,006 s a Perplexity po 11,954 s; i tyto hodnoty zahrnují polling. Dva případy a rozdílné účty nestačí pro žebříček latence. Náklady, tokeny a kredity, které UI nezobrazilo, zůstávají unknown.

CIT-001 ChatGPT měl před odesláním stále štítek Personalizovaný; vypnutí nebylo ověřeno. U čerstvého CIT-020 již UI výslovně potvrdilo Bez personalizace. Gemini používal Plus. Tyto odchylky jsou zachované, nikoli prohlášené za homogenní měření bezplatných účtů. Další analytický sběr vyžaduje schválené nastavení G1.

9.0.ii. *Integrita citací a automatická kontrola:*

Původní Perplexity CIT-001 má v inline odkazu DOI `NEJMoa2200674`, zatímco textový seznam uvádí `NEJMoa2034577`. Rozdíl je zachovaný; odkaz se neopravoval. Nový Perplexity CIT-020 má sdružené citační čipy. Operátor otevřel jejich skutečné UI karusely: 9 skupin obsahovalo 15 původních zdrojových vazeb. Normalizace v2 zachovává všechny cílové URL na původních místech; původní v1, raw HTML a doklad karuselů zůstaly uložené. Jde o opravu exportu, nikoli modelové odpovědi.

`check_citations.py --pilot` zpracoval 8 nových odpovědí: 54 anotačních řádků, 3 automaticky identifikovaná necitovaná tvrzení a HTTP kontroly 11 unikátních URL. Oba lidé mají připravené totožné podklady pro všech 8 odpovědí; proto je rozsah druhého pilotního hodnocení 100 %. Parserové jednotky musí lidé přezkoumat; automatický HTTP stav neprokazuje zdrojovou oporu ani pravdivost. Listy jsou dosud nevyplněné, nejde o provedené nezávislé ratingy.

9.0.iii. *Co z těchto dat nelze vypočítat:*

G1/G2/G3 nejsou splněny. Chybí analytická matice dev/val/test/repeat, lidské ratingy, P3_final a schválený holdout. Proto není vykázána finální citační precision/recall, správnost s CI, H1/H2, přenos P3, repeat variabilita, raw IRR ani Pareto/index úsilí. `score.py --final` nebyl spuštěn na skutečných datech bez G3. Syntetické výsledky softwarových testů se do výsledků produktů nepřidávají.

9.0.iv. *Návrh komentáře týmu:*

9.a. Komentář týmu k pilotu – návrh k úpravě autory

Text v první osobě je návrh připravený AI z reálných pilotních podkladů. René a Jan jej mohou upravit; není záznamem jejich již provedených nezávislých ratingů.

V pilotním sběru jsme s podporou AI operátora získali deset odpovědí na dvě otázky. Při porovnání těchto výstupů považujeme za podstatné, že samotný správný hlavní údaj ještě nestačí k důvěře v citace. U vakcíny se objevoval údaj 95 %, ale v původní odpovědi Perplexity vedl inline odkaz na jiné DOI než textový seznam zdrojů. Takový rozpor bychom při běžné práci snadno přehlédli.

U Shakespeara hodnotíme jako pozitivní, že nové výstupy odlišily neznámé datum narození od doloženého křtu a tradičních narozenin. Současně vidíme, že dobrovolné historické podrobnosti přidávají další tvrzení, která je třeba ověřit. Naše hodnocení má proto kontrolovat celou odpověď, ne jen její první správnou větu.

Pilot také ukázal význam věrného exportu. Citace Perplexity sdružené pod +1 nebo +2 nelze přenést jako jediný odkaz. Zachovali jsme původní text i HTML a samostatně zdokumentovali všechny odkazy z původních karuselů. Neopravovali

jsme tím odpověď produktu; připravili jsme podklady, ze kterých se dá její atribuce posoudit.

Za hlavní omezení nyní považujeme malý počet různých úloh, rozdílné účty a některé intervaly ovlivněné prodlevou zachycení. Z těchto dat nevyhlašujeme nejlepší produkt ani vítězný prompt. Nezávislé hodnocení lidí a úplný zmrazený benchmark jsou další nutný krok, nikoli hotový výsledek této pilotní kolekce.

10. Analýza pilotních výstupů

Skutečná data zatím pokrývají **2 unikátní úlohy a 10 odpovědí**. Tato analýza nenaplňuje požadavek zadání na alespoň 8 unikátních úloh; deset odpovědí na dvě otázky se za osm různých případů nevydává. Níže jsou konkrétní pozorování AI operátora, která mají lidé přezkoumat. Nejde o nezávislé lidské ratingy.

Úloha / kolekce	Konkrétní pozorování	Interpretace a omezení
CIT-001 / původní Perplexity	Inline DOI a DOI v seznamu se liší	Riziko nesprávné atribuce; zachovat oba původní odkazy. Příčina retrievalu/generování není doložena: unknown.
CIT-001 / původní ChatGPT	Hlavní účinnost 95 %; text používá confidence interval	Originální studie používá Bayesian credible interval; přesnou terminologii a závažnost musí posoudit hodnotitel.
CIT-001 / nový ChatGPT	Hlavní účinnost 95 %; výstup přiznává blokované otevření plného textu	Úspěch hlavního údaje a transparentní omezení přístupu; samotná deklarace neprokazuje přečtení všech zdrojů.
CIT-001 / nový Grok a Gemini	Hlavní údaj 95 %; citace na PubMed záznam původní studie	Pozitivní protipříklad pro hlavní odpověď; všechna dobrovolná tvrzení musí být ověřena zvlášť.
CIT-020 / nové produkty	Přesné narození přiznávají jako neznámé a odlišují křest od tradice narozenin	Pozitivní práce s nejistotou; tradiční datum se nevydává za jistý rodný záznam.
CIT-020 / nový Perplexity	Tvrzení „earliest plausible birth date“ jde nad prosté odlišení tradice od dokladu	Požaduje kontrolu zdrojové pasáže; bez ní nepřidělujeme S2. Úplné sdružené citace jsou zachovány v normalizaci v2.
CIT-020 / nový ChatGPT a Grok	Dobrovolné historické podrobnosti nad hlavní otázku	Více tvrzení zvyšuje rozsah nutné verifikace; nejsou dalšími povinnými RF.

Pro finální analýzu je stále nutných ≥8 různých task_id, včetně úspěchů, selhání a protipříkladů, vazby na run_id/pair_id a doložené zdrojové pasáže. Retrieval/

attribution/generation jsou hypotézy; bez přímého důkazu se uvádí unknown. Lepší P3 sám neprokazuje opravu mechanismu. Pilotní případy nejsou finální test.

11. Harmonogram a role

Projekt trvá 10 týdnů a má tři brány, za které se nevracíme. Role jsou rozdělené tak, aby autor promptu neviděl testovací sadu.

11.a. Brány

Brána	Co se zmrazí	Kdy
G1	Zmrazení protokolu	Před prvním analytickým během (pilot navíc je před G1)
G2	Zmrazení P3	Před otevřením testovací sady
G3	Konec hodnocení	Před finálním scoringem (val scoring před G2)

> **Note**
>
> Týdny jsou relativní; tým je přepíše na data semestru. Pevné je jen pořadí: G1 před prvním analytickým během, G2 před otevřením testovací sady, G3 před finálním scoringem. Validační scoring probíhá před G2.

11.b. Role

Role	Odpovědnost	Omezení
Koordinátor protokolu	Protokol, metadata běhů, dodržení 72hodinového okna	—
Správce dat	Testovací sada, hash, validace případů, zaslepení anotačního listu	Nesdílí testovací případy s autorem promptu
Autor promptu	P2, kandidáti P3, changelog	Neotevře testovací sadu před zmrazením P3
Analytik	Skripty, bootstrap, grafy, reprodukovatelnost balíčku	—
Hodnotitelé (všichni)	Lidské hodnocení, dvojité hodnocení 25 % odpovědí	Nehodnotí běhy, které sami spouštěli

11.c. Potvrzené přiřazení a sběr

Uživatel 12. 10. 2026 určil Reného Mrákavu a Jana Duba jako dva plánované lidské hodnotitele a pověřil agenta skutečným sběrem v Avast Secure Browser. Operátor nového pilotu je `codex-ui-2026-10-12`; jeho výstupy budou hodnotit lidé. Přiřazení rolí není doklad provedené kalibrace nebo ratingů. Uživatel následně potvrdil: **René Mrákava je správce skrytého testu a nezávislý ověřovatel referencí; Jan Dub je autor promptu.** Přípravu podkladů pomáhá provést operátor AI; Janovi se obsah testu před G2 nepředává. Lidské ověření, kalibrace a nezávislé ratingy zůstávají skutečnými úkony lidí. Nehodnotící operátor uchovává anotační klíč a automatické nápovědy odděleně od Reného i Jana; René jako správce testu nepotřebuje produktový klíč. Operátor po přípravě a čtení testových kandidátů dále nenavrhuje ani neladí P3.

Všech pět produktů zůstává v návrhu. Uživatel výslovně zvolil pokračování s Claude po obnovení limitu, nikoli jeho vyřazení. Pilot 12. 10. ukázal limit sdílený s Claude Code a oznámené obnovení 13. 10. v 19:00.

Původní pilot jiného operátora se uchovává odděleně. Nový sběr používá existující přihlášené účty; jejich skutečné úrovně se zapisují do metadat (u Gemini byl pozorován Plus). Původní plán bezplatné úrovně proto nelze prohlásit za ověřený. Definitivní srovnávací konfigurace patří před G1.

12. Limity a co výsledky neprokážou

Výsledek bude porovnáním pěti produktů na 40 konkrétních dotazech v jednom časovém okně. Nebude to měření schopnosti jazykových modelů ani obecný žebříček.

Limit	Důsledek	Co s tím děláme
Malý vzorek (10 testovacích případů)	Široké intervaly, malé rozdíly nerozlišíme	Velikost efektu a intervaly, doplňkové výsledky z vývoje
Produkty se mění	Model, rozhraní i vyhledávání se mohou změnit během dnů	72hodinové okno, záznam viditelného modelu a data
Web se mění	Zdroj může zmizet nebo se změnit mezi během a hodnocením	Hodnocení do 7 dní od běhu, snímky obrazovky, archivace stránky
Bez parity nástrojů	Rozdíly nelze připsat modelu	Závěry formulujeme jen o produktech
Úroveň účtu a personalizace	Nový pilot používá existující účty, Gemini Plus; rozdíl úrovní může výsledek ovlivnit	Před G1 sladíme konfiguraci nebo deklarujeme rozdíly; úroveň/model u každého běhu
Jedno kolo a povolené standardní doptání	Neměříme volnou vícekolovou konverzaci; případné druhé kolo zaznamenáme	Uvedeme jako hranici platnosti
Dotazy sám zvolil tým	Známá fakta může model znát i bez vyhledávání	Hodnotíme citaci, ne jen odpověď; dev/val mají 13/30 edge (43,3 %), nový test ještě není hotový
Hodnotitelé jsou studenti	U odborných zdrojů (právo, zdraví) mohou chybovat	Kalibrace, dvojité hodnocení, zlaté zdroje v případu
Dělení na tvrzení je subjektivní	Počet dvojic se může mezi hodnotiteli lišit	Pravidla v rubrice, člověk kontroluje celou odpověď ve všech podmínkách, bez limitu osmi tvrzení
Jen čeština a angličtina, česká IP	Jiné jazyky a regiony mohou dopadnout jinak	Uvedeme jako hranici platnosti

Co výsledky prokázat mohou

Zda se na této sadě a v tomto období liší citační přesnost produktů a zda strukturovaný prompt u jednotlivých produktů pomáhá. Také jaké typy chyb citací se opakují.

Co prokázat nemohou

Který jazykový model je lepší, jak se produkty chovají na jiných typech dotazů a zda rozdíly vydrží po další aktualizaci produktu.

13. Reprodukovatelný balíček

Centrem projektu je `ENC-AI-Project`. Originální sběr a hashově svázané auditní artefakty jsou mimo worktree, aktuálně v sousední `czai-private-v1`. Podepsané soubory se při přenosu nepřepisují. Po G3 se do projektu přidá schválený export dat, běhů a výsledků pro odevzdání. Reprodukce využije původní auditní balíček a read-only mapu cest podle `freeze/README.md`.

#	Povinný výstup	Umístění a skutečný stav
1	Výzkumný protokol	`PROTOCOL.md`, rubrika, `freeze/README.md`; G1/G2/G3 zatím nepodepsané
2	Benchmarková data	Dev 20, val 10 v `data/`; soukromý návrh 10 nových testů čeká na lidské schválení; RF/OF evidence připravena k ověření
3	Prompty a historie	`prompts/`; P1/P2 a kandidáti existují, P3_final se vybere z validace
4	Metadata a původní výstupy	`runs/README.md`, generátor a pilot; analytické běhy zatím neexistují
5	Kód a rubrika	`scripts/`, `annotation/`, `tests/`; softwarové testy jsou oddělené od experimentu
6	Výsledky a nejistota	Výsledky skutečného pilotu, `results/README.md`; finální CSV vyžadují skutečné ratingy a G3
7	Analýza ≥8 unikátních úloh	`analysis/`, \#error-analysis; zatím plán
8	Závěrečná zpráva	MyST zdroje v `docs/` a PDF `docs/exports/project.pdf`; pracovní verze

Worksheet je v `docs/deliverables/worksheet.md`. Stav povinností je v `docs/deliverables/README.md`. Připravujeme **PDF i zdroje** a kompletní oprávněný auditní balíček; formát vyžadovaný vyučujícím zatím nebyl potvrzen. Žádný ZIP zatím není vydáván za dokončené odevzdání.

13.a. Kontrola a sestavení

```
python3 scripts/validate_cases.py --no-test
PYTHONDONTWRITEBYTECODE=1 python3 -m unittest discover -s tests -v
uv run --locked ruff check .
uv run --locked ruff format --check .
cd docs
uv run --locked myst build --pdf
```

Skripty podporují Python 3.9+ a standardní knihovnu. Dokumentační nástroje mají oddělené uv prostředí podle `pyproject.toml` a `uv.lock`. PDF ani zelené testy neověřují reference a nenahrazují benchmark.

Úplné příkazy s povinnými G1/G2/G3 manifesty, soukromými cestami, exporty pro hodnotitele a finálním scoringem jsou v `HANDOFF.md`. Citlivé snapshoty a přihlašovací údaje nepatří do Git exportu.