Správnost citací AI asistentů s webovým vyhledáváním

Jan Dub[1], **René Mrákava**[1], and **Nikolas Nosál**[1]

[1]Mendelova univerzita v Brně, Provozně ekonomická fakulta

Abstract

Studie hodnotí podporu tvrzení citovanými zdroji u AI produktů s webovým vyhledáváním. Sběr obsahuje 40 různých úloh a 93 uložených věcných odpovědí, z nich 92 podkladů pro nezávislé lidské hodnocení. Gemini má 9 nových otázek v P1/P2/P3A. Opravené AI posouzení pilotu uvádí 47 ze 48 RF správně; vybraný citační subset má precision 0,7954 (11 dokončených odpovědí, 99 explicitních párů). Lidské listy jsou zaslepené a ratingy prázdné. Úplná produktová matice, skutečné lidské ratingy a původní G1/G2/G3 nejsou dokončené.

Keywords správnost citací, atribuce zdrojů, generativní vyhledávače, jazykové modely s vyhledáváním, halucinace

ENC-AI Project

Published Oct 13, 2026

Acknowledgements
Mendelova univerzita v Brně, Provozně ekonomická fakulta. Všichni autoři přispěli k vypracování zadání.

Data Availability
Protokol, data, prompty, skripty a testy jsou dostupné na https://github.com/Nouzl0/ENC-AI-Assignment-2.

1. Shrnutí

Studie sleduje podporu tvrzení jejich citovanými zdroji u rešeršních AI produktů. Aktuální export obsahuje **40 různých úloh, 93 věcných odpovědí a 92 podkladů pro lidské hodnocení**. Původních 33 odpovědí je oddělených od doplňku. Deset nových otázek vzniklo po byte/hash fixaci šablon; nyní už jsou zveřejněné. Původní chybné zachycení SUP-H002/P2 je vyřazené, náhrada vybraná jednou.

Odpovídaly ChatGPT, Gemini, Grok a Perplexity; Claude neměl dokončenou odpověď. Účty a konfigurace se liší. Gemini má 9 nových otázek ve všech třech podmínkách P1/P2/P3A. P3A zůstal předem fixovaný, nevyhlašuje se validačním vítězem.

1.a. Výsledky a kontrola

AI obsahové posouzení všech 33 pilotních odpovědí našlo 47 ze 48 RF správně: makro pokrytí 0,9848, bootstrap 95% interval 0,9516–1,0000. Opravený atomizovaný subset 11 dokončených odpovědí na CIT-004, CIT-008 a CIT-013 má 99 explicitních párů: 78 S2, 1 S1, 20 S0. Makro precision je 0,7954 (CI 0,7265–0,8433). Po započtení jednoho terminálního selhání jako nuly jde o 0.7291 z 12 pokusů. Tři záměrně vybrané klastry neumožňují obecný žebříček ani potvrzení H1/H2.

Čtyři starší clipboard exporty byly obnoveny z tehdejších záznamů, bez nového modelového běhu. Nové exporty čtou text a href přímo z příslušného DOM, bez schránky. Reference deseti doplňkových otázek mají AI důkazy pro 18 RF; nezávislá lidská kontrola zůstává nutná.

1.b. Lidské hodnocení a rozsah

Zaslepené listy mají prázdné ratingy. První hodnotitel pokryje všechny způsobilé odpovědi; druhý ≥25 % v každém stratu fáze × produkt × podmínka. Klíč, značky produktů a automatické návrhy ratingů se nepředávají. Postup je v Předání nezávislým hodnotitelům. Intervaly AI auditu nezahrnují chyby hodnotitele ani lidskou shodu.

Plná vyvážená matice, nezávislé ratingy a původní G1/G2/G3 nejsou dokončené. Pozdější ratingy exploratorních dat nemohou zpětně schválit původní brány nebo obnovit utajený holdout. Aktuální podklady jsou připravené k přezkumu, nikoli vydávané za úplný potvrzující experiment.

2. Výzkumná otázka a hypotézy

AI asistenti s webovým vyhledáváním (ChatGPT, Gemini, Claude, Perplexity, Grok) připojují k odpovědím odkazy, které působí jako důkaz. U rešerše je ale důležité, zda zdroj skutečně podporuje právě to tvrzení, u kterého stojí. Zadání nás vede k porovnání **produktů jako celků** (model + vyhledávání + rozhraní), ne izolovaných modelů; schopnost modelu bez vyhledávání neměříme.

> **Výzkumná otázka**
>
> Jak často citovaný zdroj skutečně podporuje tvrzení u pěti produktů na 40 faktických rešeršních úlohách v češtině a angličtině a jak tuto podporu mění strukturovaný prompt (P2) a prompt optimalizovaný na vývojových datech (P3) oproti společné výchozí podmínce (P1)?

Praktický význam: uživatel se na odkaz spoléhá a ověřuje jej jen výjimečně; zajímá nás, kdy je to oprávněné.

2.a. Hlavní metrika

Citační přesnost = podíl explicitně citovaných dvojic tvrzení–zdroj, které zdroj plně podporuje (S2). Je to průměr přes odpovědi, každá úloha má stejnou váhu. Vedlejší metriky jsou úplnost citací a správnost odpovědi; S2 neznamená, že je tvrzení pravdivé. Definice jsou v Hodnocení: metriky, lidé a nejistota.

2.b. Hypotézy

Obě hypotézy se vyhodnotí **výhradně na držené testovací sadě** po zmrazení protokolu a promptu.

	Tvrzení	Rozhodovací pravidlo
H1	Předem zvolený produkt (výchozí Perplexity), který je postaven na vyhledávání, má v P2 vyšší přesnost než průměr ostatních.	Rozdíl ≥ 0,10 a dolní mez 95% párového bootstrapového CI > 0
H2	Strukturovaný prompt P2 zvyšuje přesnost oproti P1 napříč produkty.	Průměrný rozdíl ≥ 0,05, dolní mez CI > 0 a kladný odhad u ≥ 4 z 5 produktů

Mechanismy (lepší vazba retrievalu na pasáže u H1; pokyn přiřadit důkaz u H2) jsou hypotézy. P3 a žebříčky jsou explorační.

H1 ve znění zadání: Za podmínek P2 a stejných úloh dosáhne Perplexity vyšší citační přesnosti než průměr ostatních produktů o ≥ 0,10, protože je vyhledávání jeho jádrem. Hypotézu budeme považovat za podpořenou, jen pokud se výsledek projeví na držené testovací sadě. **H2:** Za týchž podmínek zvýší P2 přesnost oproti P1 o ≥ 0,05, protože žádá přiřazení důkazu a přiznání nejistoty; podpora vyžaduje shodu na testovací sadě.

Co by hypotézy vyvrátilo: rozdíl H1 pod 0,10 nebo interval zahrnující nulu; H2 s kladným efektem jen u 1–2 produktů nebo se zhoršením jiných. Prompt, který jednomu produktu pomůže a ostatním uškodí, hlásíme jako platný výsledek.

2.c. Alternativní vysvětlení

Alternativa	Jak ji kontrolujeme
A1: Produkt cituje méně tvrzení, proto „přesněji“	Úplnost citací, počet tvrzení a citací na odpověď
A2: Rozdíl dělá dostupnost zdrojů, jazyk nebo obor	Podíl NA, členění podle jazyka a oboru (CZ/EN nejsou párované překlady)
A3: P2 jen změní formát citování	Podíl explicitně citovaných odpovědí a přesnost podmíněná jejich výskytem

3. Návrh: produkty, data a prompty

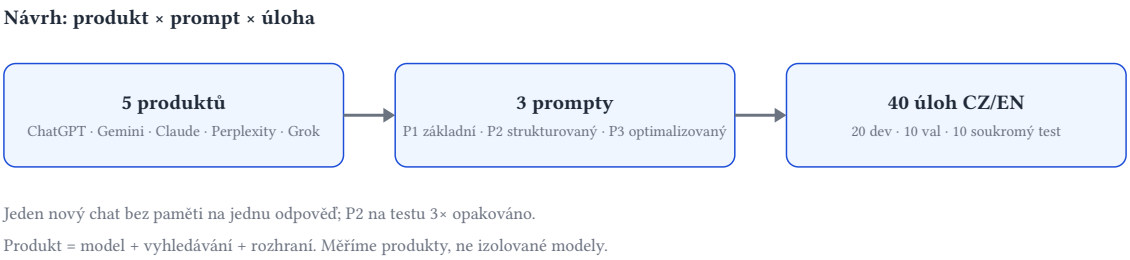


Figure 1: Návrh studie. Produkt je celek model + vyhledávání + rozhraní.

3.a. Porovnávané produkty

Používáme **běžné webové rozhraní** každého produktu s jeho vlastním vyhledáváním; paritu nástrojů zajistit nelze (každý produkt má jiný index a zobrazení citací), proto jsou závěry formulované o produktech. Claude Code je nástroj pro programování, a proto jej nezahrnujeme (mimo směr B). Pilot probíhal v prohlížeči Chrome na existujících účtech.

Produkt	Vyhledávání	Režim bez paměti	Vyloučený režim
ChatGPT	Vynucený nástroj Search	Temporary chat, bez personalizace	Deep research
Gemini	Automaticky	Temporary chat	Deep Research
Claude	Web search	Incognito chat	Research
Perplexity	Vždy, režim Search	Incognito	Research, Labs
Grok	Automaticky (web a X)	Private Chat	DeepSearch

Pravidla běhu: každý dotaz v novém chatu bez paměti a vlastních instrukcí; jedno kolo komunikace (při doptání odpovíme „Pokračujte podle svého nejlepšího úsudku.“); uložíme text, všechny URL citací, snímek a metadata (viditelný model, tarif, čas, selhání, opakování). Pořadí produktů losuje skript (seed 2026); jeden případ projde všemi produkty do 24 h, celá sada do 72 h. **Zvolený přístup k nástrojům:** *podle schopností produktu*; výsledky jsou výslovně porovnáním produktů, ne čisté měření modelu.

Zdroj výkonnosti	Oddělíme?	Jak
Vliv promptu	Ano	Stejný produkt v P1, P2 a P3
Vliv nástrojů	Částečně	Evidujeme, zda proběhlo vyhledávání a kolik zdrojů se zobrazilo
Schopnost modelu	Ne	Ve spotřebitelském rozhraní nelze model odpojit od vyhledávání
Vliv produktu	Ne	Rozhraní, bezpečnostní vrstva a vyhledávač tvoří celek

Metadata každého běhu (`runs/`): produkt a viditelný model, rozhraní a tarif, datum a čas, podmínka a verze promptu (SHA-256), systémová instrukce („výchozí, neviditelná“), oprávnění nástrojů, kontextové soubory (žádné), teplota a délka výstupu („výchozí, nenastavitelné”), počet kol a viditelných volání nástrojů, latence, náklady/tokeny (nebo *unknown*), opakování, typ selhání a ruční zásahy.

3.b. Testovací sada

Návrh obsahuje **40 různých úloh**: 20 vývojových, 10 validačních a 10 soukromých testovacích. Dev a val jsou veřejné v `data/`. Testovací sada je **uložená mimo Git** a autor promptu ji před zmrazením P3 neotevře; po jejím zveřejnění nelze použít jako skrytý test. Validátor ověřuje schéma a stratifikaci, nikoli pravdivost referencí.

Tato část popisuje plán plného experimentu. Aktuálních SUP-H001–010 už je zveřejněných a všechny mají typ fact/medium; nenaplňují původní testové kvóty ani utajení. Pro potvrzující experiment je třeba jiná nezávislá skrytá sada.

Vlastnost	Vývoj: skutečnost (20)	Validace: skutečnost (10)	Test: soukromý návrh (10)
Oblasti: věda a zdraví / právo / IT / ekonomika / historie a kultura	4 / 4 / 4 / 4 / 4	2 / 2 / 2 / 2 / 2	2 / 2 / 2 / 2 / 2
Jazyk: CZ / EN / CZ+EN	10 / 9 / 1	5 / 4 / 1	4 / 5 / 1
Typ: fakt / primární zdroj / syntéza	10 / 6 / 4	3 / 4 / 3	5 / 3 / 2
Obtížnost: snadná / střední / těžká	3 / 11 / 6	4 / 4 / 2	1 / 6 / 3
Okrajové případy	9 (45 %)	4 (40 %)	4 (40 %)

Table 1: Složení testovací sady

3.b.i. *Okrajové případy:*

Okrajové případy jsou záměrně zastoupeny ze 43 % (13 ze 30 veřejných úloh), aby měřily hranice chování a ne jen snadné otázky.

- **Nepravdivý předpoklad** (2×): „Proč musí mít kandidát do Senátu ČR alespoň 35 let?“ arrow.r Opravit na 40 let, čl. 19 odst. 2 Ústavy
- **Protichůdné zdroje** (2×): Nadmořská výška Sněžky (1602 vs. 1603 m) arrow.r Uvést obě hodnoty a důvod rozdílu
- **Chybějící informace** (3×): Přesné datum narození Shakespeara arrow.r RF: přiznat, že přesné datum není známo; křest je pouze OF
- **Nejednoznačné zadání** (2×): „Kdy vznikla Česká republika?“ arrow.r RF: samostatná ČR 1. 1. 1993; 1969/1990 jsou pouze OF
- **Časové omezení** (1×): Aktuální sazba ECB, jen zdroje z posledních 30 dní arrow.r Uvést hodnotu, datum účinnosti a datum zdroje
- **Nedávná změna faktu** (1×): Podpora Windows 10 a program ESU arrow.r Ověřit stav pro daný produkt a datum
- **Kombinace češtiny a angličtiny** (2×): Co znamená SBOM a který exekutivní příkaz ho prosadil arrow.r Odpovědět česky, termíny ponechat

Každý případ má všech 13 polí schématu ze zadání (`task_id` … `source_or_provenance`) a původ dat. Reference mají tři části: **RF** (povinná fakta), **OF** (nepovinná fakta, jejich vynechání se netrestá) a **RC** (požadavky na formát a zdroje). Dynamické případy mají samostatnou evidenci pro každý UTC den běhu. Všechny dotazy jsou syntetické, jen o veřejných faktech, bez osobních údajů a autorských textů. Stav kontroly referencí je v příloze Kontrola referencí před G1.

3.c. Prompty

Všechny tři podmínky dostanou stejnou otázku; liší se jen obalem. Anglické úlohy používají překlad stejné šablony (všechny verze jsou v `prompts/`). Úpravy pro konkrétní produkt jsou zakázány.

P1 – společná výchozí podmínka:

```
Vyřešte níže uvedenou úlohu. Odpovězte pouze v požadovaném formátu.

Úloha:
{user_prompt}
Formát: stručná odpověď s odkazy na použité zdroje (URL).
```

P2 – strukturovaný prompt (verze 1.0, napsán před prvním během): žádá otevření skutečných zdrojů, odkaz u každého tvrzení, primární zdroje, opravu chybných předpokladů, uvedení obou hodnot při rozporu zdrojů, přiznání nejistoty a pevný formát ODPOVĚĎ / TVRZENÍ / ZDROJE / JISTOTA.

Plné znění P2:

```
Jste pečlivý rešeršní asistent. Každé tvrzení dokládáte zdrojem, který jste v této konverzaci
skutečně otevřeli.

Cíl: odpovězte přesně a stručně na otázku tak, aby si čtenář mohl každé tvrzení ověřit.

Otázka:
{user_prompt}

Pravidla:
1. Vyhledejte informace na webu. Necitujte zdroj, který jste neotevřeli, a nevymýšlejte URL.
2. Za každým faktickým tvrzením (číslo, datum, jméno, definice) uveďte odkaz na zdroj ve tvaru [1],
[2].
3. Citujte konkrétní stránku nebo dokument, ne domovskou stránku ani výsledky vyhledávání.
4. Upřednostňujte primární a oficiální zdroje (zákon, úřad, původní studie, standard).
5. Pokud otázka obsahuje chybný předpoklad, nejprve ho opravte.
6. Pokud se zdroje liší, uveďte obě hodnoty, každou s vlastním zdrojem, a vysvětlete rozdíl.
7. Pokud otázka omezuje stáří zdrojů, použijte jen zdroje, které omezení splňují, a uveďte jejich
datum.
8. Pokud spolehlivou odpověď nenajdete, napište to. Nehádejte.

Formát výstupu:
ODPOVĚĎ: 1–3 věty s přímou odpovědí.
TVRZENÍ:
T1: <jedno tvrzení> [n]
T2: <jedno tvrzení> [n]
ZDROJE:
[1] <název> – <vydavatel> – <datum vydání nebo „neuvedeno"> – <úplná URL>
JISTOTA: vysoká / střední / nízká – jedna věta proč.
```

P3 – optimalizovaný prompt: vzniká z P2 jen na vývojových a validačních datech. Úprava je povolená jen proti typu chyby, který se objevil alespoň třikrát; kandidáti jsou P3-A (úryvek ≤ 25 slov ke tvrzení) a P3-B (navíc kontrola před odesláním). Vítěz se vybere jednou na validaci (přepočet v plné přesnosti), zkopíruje se přesně do P3_final a po zmrazení se neladí. P3 nesmí obsahovat pokyny pro konkrétní úlohy. Historie verzí je v `prompts/CHANGELOG.md`.

4. Hodnocení: metriky, lidé a nejistota

Citace metod jsou v Příloha C: zdroje a použití AI.

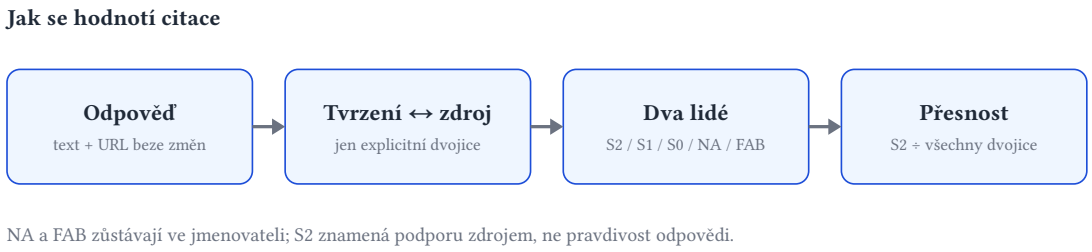


Figure 2: Postup hodnocení. Citace se nikdy neopravují ani nedoplňují.

4.a. Jednotky a hodnocení

Tvrzení je atomický faktický výrok (číslo, datum, jméno, definice, vztah); hodnotí se celá odpověď, ne jen sekce TVRZENÍ. **Dvojice** je tvrzení a zdroj, který k němu produkt skutečně připojil; souhrnný seznam zdrojů bez vazby je jen diagnostika. Každá dvojice dostane jedno hodnocení:

Rating	Pravidlo
S2	Zdroj plně podporuje tvrzení v uvedené přesnosti
S1	Podporuje jen část nebo užší tvrzení
S0	Tvrzení neobsahuje nebo mu odporuje
NA	Obsah zdroje se nepodařilo přečíst (např. paywall); nepočítá se jako nepravda
FAB	Zdroj neexistuje (doložená halucinace)

Úplná pravidla a kalibrační kotvy jsou v `annotation/rubric.md` a `annotation/calibration.md`.

4.b. Metriky

Citační přesnost (hlavní metrika) – NA a FAB zůstávají ve jmenovateli; bez explicitních citací nebo při konečném selhání je přesnost nula.

$$\text{Přesnost}_a = \frac{|\ \text{explicitní S2 dvojice odpovědi } a\ |}{|\ \text{všechny explicitní dvojice odpovědi } a\ |} \tag{1}$$

Úplnost citací – podíl tvrzení s alespoň jednou citací S2 (tvrzení bez citace = 0).

$$\text{Úplnost}_a = \frac{|\ \text{tvrzení s alespoň jednou citací S2}|}{|\ \text{všechna hodnocená tvrzení}|} \tag{2}$$

Správnost odpovědi – skóre 0–2 proti referenci; 2 vyžaduje všechna povinná fakta (RF) a splněné požadavky (RC). Vynechání nepovinných faktů se netrestá.

Diagnostika: podíl FAB a NA, kvalita zdrojů (primární/oficiální), dodržení časového omezení, přiznání nejistoty, počet tvrzení a citací na odpověď. **Provoz:** první a konečná úspěšnost, latence, opakování, náklady; neznámé hodnoty (tokeny, kredity) se uvádějí jako *unknown*, nikdy jako nula.

Automatizované kontroly: parser odpovědí a citací zachovává původní text a URL, validátor schématu a stratifikace (`validate_cases.py`) hlídá duplicity a překryv sad, HTTP kontrola URL je jen diagnostika. Automatika nikdy nepředvyplňuje ratingy.

Přenositelnost promptu (P2 a P3 oproti P1): průměrné zlepšení, zlepšení po produktech a na testu, délka promptu, počet úprav pro konkrétní produkt (cíl 0) a dodatečná kola či volání nástrojů.

Kvalita vs. úsilí: předem stanovený explorační index `přesnost − 0,1·L_norm − 0,1·T_norm` (normalizovaná latence a čas anotace); při chybějících časech místo něj uvádíme Pareto-frontu přesnosti a latence.

4.c. Dva nezávislí hodnotitelé

Hodnotí **René Mrákava a Jan Dub**; operátor, který odpovědi sbíral, je nehodnotí. Oba dostanou stejné zaslepené listy v náhodném pořadí (seed 2026) bez automatických nápověd, produkt a podmínka jsou skryté. První hodnotitel posoudí všechny odpovědi, druhý předem náhodně vybraných **≥ 25 % v každém stratu** (fáze × produkt × podmínka; zadání vyžaduje nejméně 20 %). Původní ratingy zůstanou zachované před diskusí; Cohenova kappa (Cohen, 1960; S2 vs. ostatní) a surová shoda se počítají z nich, ne z konsenzu. Neshody se auditují a nevyřešené rozhoduje třetí člověk. Automatické kontroly (HTTP dostupnost, shoda entit) slouží jen správci. Původní hlavní analýza vyžaduje lidské ratingy. Od 13. 10. vzniká oddělené pomocné AI hodnocení podle stejné rubriky (Doplňkový sběr a výslovně označené AI hodnocení); nesplňuje lidskou složku zadání, není lidskou shodou a neopravňuje finální skórování G3.

4.d. Nejistota

- **Párový bootstrap po úlohách** (Efron, 1979; 10 000 převzorkování, seed 2026) pro H1 a H2 – všechny produkty řeší stejné úlohy, takže párování odstraní rozptyl obtížnosti.
- **Wilsonův 95% interval** (Wilson, 1927) pro binární podíly.
- **Variabilita běhů:** P2 se na testu opakuje 3×; hlásíme směrodatnou odchylku a změny správnosti mezi běhy.
- S 10 testovacími úlohami budou intervaly široké; rozdíly pod zhruba 15 procentních bodů pravděpodobně nerozlišíme. Uvádíme proto velikost efektu a interval, ne jen „signifikanci“.

4.e. Selhání a opakování

Neúspěšný běh je součástí dat. Opakování je povoleno jen u selhání mimo model (chyba nástroje, limit požadavků, výpadek produktu, časový limit) a vždy se hlásí **úspěšnost na první pokus i po opakování**. Výstup modelu (odmítnutí, chybějící citace, halucinace) se neopakuje a hodnotí se normálně. První pokusy se nemažou ani po úspěšném opakování.

5. Výsledky skutečného pilotu

Pilot zachytil odpovědi čtyř produktů a přístupové omezení pátého, a poskytl první pozorování chyb citací. Je to **provozní a kvalitativní výsledek na malém vzorku**, ne odhad citační přesnosti produktů. Originály (text, HTML, snímek, metadata, SHA-256) jsou v `runs/pilot-2026-10-12/` a `runs/pilot-2026-10-13/`, souhrn řádků v `results/pilot/run_summary.csv`.

Výsledky v kostce

- **33 skutečných odpovědí** na **8 úloh** od **4 odpovídajících produktů**; pátý měl přístupové omezení, každá uložená s textem, HTML, snímkem a SHA-256.
- **95,8 %** (23 z 24) odeslaných prvních pokusů rozšířeného pilotu skončilo odpovědí, bez jediného opakování.
- **183 citovaných dvojic** tvrzení–zdroj z 31 odpovědí zpracováno parserem, **59 unikátních URL** zkontrolováno.
- **Pět konkrétních nálezů** o chybách citací, přiznání nejistoty a věrnosti exportu (Analýza osmi skutečných pilotních úloh).
- Orientační proxy podpory citací: **0,49–0,76** podle produktu (předběžné, bez lidských ratingů).
- **Rozsah:** finální citační přesnost a testy hypotéz nejsou součástí této verze (omezený čas a rozpočet), viz Limity a platnost výsledků.

5.a. Rozsah

Sběr	Úlohy	Odpovědi	Poznámka
Původní pilot (12. 10.)	CIT-001, CIT-020	10	8 odpovědí (ChatGPT, Gemini, Grok, Perplexity) + 2 z původního anonymního pilotu; Claude: limit
Rozšířený pilot (13. 10.)	CIT-003, 004, 005, 008, 012, 013	23 z 24 odeslaných	Úlohy zvoleny před odesláním, všechny v P2; 6 řádků Claude neodesláno
Celkem	**8 unikátních úloh**	**33**	Kolekce se neslučují do jednoho skóre

Šest úloh rozšířeného pilotu bylo určeno před odesláním. Pilot je navíc před zmrazením protokolu a do budoucí analytické sady se nepřebírá. Sběr probíhal v Chromu v nových chatech v režimu bez paměti na existujících účtech.

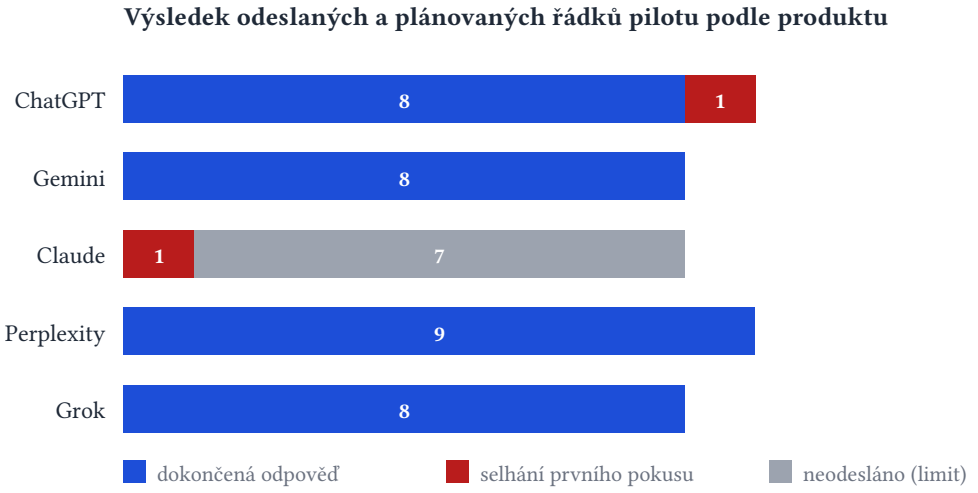


Figure 3: Výsledek všech řádků pilotu podle produktu (data: `results/pilot/operational_summary.csv`).

5.b. Provozní výsledky

Produkt	Rozšířený pilot: dokončeno / odesláno	Pozorování
ChatGPT	5 / 6	1 selhání: chyba načtení odpovědi CIT-004; částečný výstup zachován
Gemini	6 / 6	—
Grok	6 / 6	Po přístupovém ověření pokračoval původní požadavek, bez nového pokusu
Perplexity	6 / 6	Citace sdružené pod „+N“
Claude	0 / 0	Limit využití; 6 řádků neodesláno (v původním pilotu 1 odeslaný pokus skončil limitem)

To je **23 dokončených odpovědí z 24 odeslaných prvních pokusů (95,8 %)**; žádný požadavek nebyl opakován, takže úspěšnost na první a konečný pokus je shodná. Neodeslaný řádek není selhání. Latence jsou horní meze (zahrnují polling a zachycení), na žebříček rychlosti nestačí. Náklady, tokeny a kredity, které rozhraní nezobrazilo, jsou *unknown*.

Zachycené nastavení: ChatGPT GPT-6 (střední), Gemini 3.6 Flash (Plus), Grok Fast, Perplexity výchozí Search, Claude Opus 5.5 (Medium). Účty a tarify se liší; homogenita účtů není ověřena a je zachována jako odchylka.

5.c. Pozorování k citacím

Perplexity: 6 odpovědí rozšířeného pilotu obsahovalo **44 citačních skupin a 57 zdrojových vazeb**, které jsme museli zachytit z původních karuselů rozhraní. Parser připravil **148 anotačních řádků** a 15 necitovaných tvrzení; HTTP kontroly 49 unikátních URL. Automatický stav URL neprokazuje podporu ani pravdivost.

Hlavní kvalitativní nálezy (úplný rozbor v Analýza osmi skutečných pilotních úloh):

- **Rozpor DOI (CIT-001, Perplexity):** inline odkaz `NEJMoa2200674` ≠ seznam `NEJMoa2034577`; správných 95 % rozpor neodstraňuje. Zachováno beze změny.
- **Přiznání nejistoty (CIT-020):** odlišené narození / křest / tradice místo jednoho čísla.
- **Rozdílné hodnoty (CIT-004):** 1 603,296 m vs. 1 602 m vysvětleno trigonometrickým bodem; dobrovolné doplňky však přidaly tvrzení vyžadující vlastní ověření.
- **Chybný předpoklad (CIT-008):** ChatGPT opravil věk kandidáta do Senátu z 35 na 40 let a rozlišil Sněmovnu; Perplexity přisoudil hranici jinému článku Ústavy.

5.d. Orientační agregované metriky (bez lidských ratingů)

Z dat v repozitáři lze spočítat provozní čísla a **lexikální proxy podpory**. Proxy není hodnocení S2: pro každou citovanou dvojici ověřuje, zda stažená stránka obsahuje klíčová čísla (případně delší slova) z tvrzení. Nečte význam, podporu spíše nadhodnocuje a stránky nečitelné prostým HTTP (403, JavaScript) vykazuje zvlášť jako *nečitelné*, ne jako nepodpořené. Slouží jako **předběžný odhad, který nenahrazuje lidské ratingy ani hlavní metriku**.

Produkt	Odpovědi	Medián latence	Citované dvojice	Proxy: podpořeno / nečitelné	Podíl (všechny / čitelné)
ChatGPT	8	12,8 s	37	28 / 5	0,76 / 0,88
Gemini	8	10,2 s	49	24 / 14	0,49 / 0,69
Grok	8	31,8 s	51	33 / 5	0,65 / 0,72
Perplexity	7	9,6 s	46	29 / 5	0,63 / 0,71
Claude	0	–	–	–	–

Table 2: Orientační metriky pilotu podle produktu (31 odpovědí z listů pro hodnotitele)

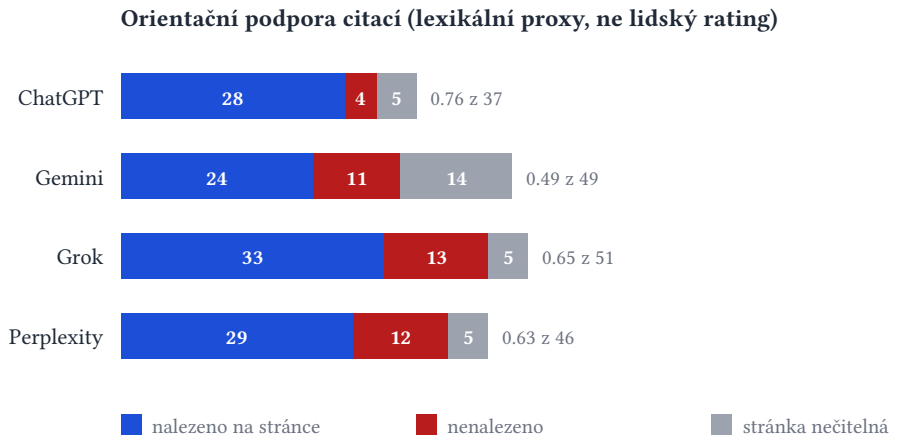


Figure 4: Podíl citovaných dvojic, jejichž klíčová čísla nebo slova lze najít na citované stránce (lexikální proxy, předběžné).

Jak to číst: u každého produktu zůstala zhruba čtvrtina až polovina citací lexikálně nepotvrzena (včetně nečitelných stránek), což potvrzuje, že odkaz bez kontroly nestačí. U Gemini je velká část stránek (14 z 49) strojově nečitelná, takže nižší podíl nelze číst jako horší citace. Rozdíly jsou na 7–8 odpovědích a

bez intervalů; **pořadí produktů z nich nevyvozujeme**. Latence jsou horní meze (včetně pollingu a zachycení); medián je robustnější než p90, které ovlivnily jednotlivé extrémy (až 1 211 s u Groku). Claude nemá žádnou dokončenou odpověď. Výpočet je reprodukovatelný skriptem `analysis/pilot_proxy.py`, výstup je v `results/pilot/pilot_metrics.csv`. Skutečná citační přesnost bude podíl lidských hodnocení S2.

5.e. Aktuální sjednocené pokrytí

Celkem je **40 různých úloh, 93 uložených věcných odpovědí a 92 způsobilých podkladů pro hodnocení**. Rozdíl jedné odpovědi je původní operátorský export SUP-H002/P2; jeho náhrada je započítaná jednou. Čtyři chybné clipboard exporty byly věrně obnoveny z původního AX a snímku, nikoli znovu vygenerované. Autentizační odmítnutí, časová selhání a neodeslané plány zůstávají v registru.

Část	Věcné odpovědi	Unikátní úlohy	Význam
Původní pilot	33	8	Historické P2
Doplňkový sběr a dokončování	60	32	Další veřejné otázky a 10 nových otázek
Celkem	93 uložených / 92 způsobilých	40	Žádný společný produktový žebříček

Gemini má 9 úplných tripletů na SUP-H001–009. Další tři veřejné otázky mají P1/P3A na Gemini a P2 od jiného produktu, proto nejsou párovým měřením promptového efektu. Poslední sběr uchovává skutečné přístupové/časové chyby; operator-capture intervaly se nevydávají za generační latenci. Registr: `runs/canonical-2026-10-13/registry.jsonl`, součty `coverage.json`.

5.f. Opravený pomocný AI audit, verze 2

Obsahové posouzení zahrnuje všech 33 původních odpovědí. Atomizovaná citační metrika se týká pouze 11 dokončených odpovědí na 3 účelově vybraných úlohách. V1 je historická verze; pro aktuální čísla se používá v2. Přesně citované stránky byly znovu kontrolované. Zrcadlo lze použít jen po doložení totožnosti dokumentu; jiný správný zdroj nemůže opravit chybnou původní citaci.

Výsledek	Rozsah	Odhad / meze	Deskriptivní 95% interval
Pokrytí RF po odpovědích	33 odpovědí / 8 úloh; 47/48 RF	0,9848	0,9516–1,0000
Obsahová správnost 0–2	33 odpovědí / 8 úloh; nejisté RC zachovány	1,8182–1,8788	Dolní mez 1,7419–1,9032; horní 1,8056–1,9667
Precision, dokončený atomizovaný subset	11 odpovědí / 3 úlohy / 99 explicitních párů	0,7954	0,7265–0,8433
Precision, terminální selhání = 0	12 prvních pokusů / stejné 3 úlohy	0.7291	0.6175–0.8433

Explicitní páry: **78 S2, 1 S1, 20 S0, 0 NA**. Všechny faktické jednotky zahrnují úvod, závěr a dobrovolné doplňky; podpůrné citované úryvky nejsou nová tvrzení. Počty jednotek závisejí na lidské kontrole

segmentace. Subset tvoří CIT-004, CIT-008 a CIT-013. Dokončený subset vynechává selhání ChatGPT/CIT-004; proto je uvedena i samostatná verze s nulou za tento pokus, v souladu s protokolem.

Bootstrap: 10 000 výběrů celých úloh s vracením, seed 20261013. Tři klastry mají hrubé diskrétní rozdělení; interval je popis tohoto subsetu, nezahrnuje chyby AI hodnotitele ani nezávislou lidskou shodu. Úplnost RF není citační recall. Žádné z těchto čísel není finální G3 skóre ani potvrzení H1/H2.

Podklady: `results/ai-review-2026-10-13-v2/`. Doplňkový audit zachovává nativní značky, přesné href a neznámé vazby. Nestandardní formát sám o sobě neznamená nepodporující zdroj; chybějící přiřazení se nesmí doplnit domněnkou.

5.g. Obsah doplňkových promptových běhů

Na deseti SUP otázkách má Gemini 30 podmínek: **29 dokončených odpovědí a jedno terminální selhání P1**. Aktivní P2 pro SUP-H002 je jeho doložená náhrada. AI porovnání s referencí našlo v dokončených odpovědích správný obsah 52/52 RF. Při zahrnutí selhání je mikro pokrytí 52/54 = 0,9630 a makro po podmínkách 29/30 = 0,9667. To měří obsah povinných faktů, **nikoli jejich citační podporu** a nikoli plnou správnost zahrnující RC a dobrovolné údaje.

P3A má také konkrétní vady: SUP-H007 uvádí chybné datum dokumentu, SUP-H008 obsahuje 30slovný úryvek při limitu 25 a SUP-H010 má neověřenou oporu na přesně uvedené URL. Nativní doménové značky ani telemetry se nepovažují za zachycený cílový odkaz. Pro doplněk proto **citační precision není spočítaná**. Podklady: `results/ai-review-2026-10-13-v2/supplement/`.

5.h. Podklady pro skutečné lidi

Zaslepený export má 92 odpovědí, prázdné ratingy a oddělený privátní klíč. Druhý hodnotitel pokrývá ≥25 % v každém stratu. Každý musí nezávisle zkontrolovat celou odpověď, RF/RC, atomizaci a původní přiřazení zdroje. Postup Předání nezávislým hodnotitelům.

6. Doplňkový sběr a výslovně označené AI hodnocení

6.a. Proč vznikl samostatný doplněk

Dne 13. 10. 2026 tým požádal o další skutečné měření a rychlé dokončení podkladů. Doplněk zachovává původní pilot i protokol. Není zpětným schválením G1, G2 nebo G3. Nové odpovědi nejsou syntetické fixture a původní lidské anotační listy se nepřepisují hodnocením AI.

Původních 33 dokončených odpovědí pokrývá osm různých úloh. Zadání požaduje nejméně **40 různých případů**, nikoli 40 odpovědí na stejné otázky. Proto se při doplňování sledují samostatně počty odpovědí, unikátních task_id a pokrytí produkt × prompt × úloha. Neodeslané plány a přístupové chyby se za odpovědi nepočítají.

6.b. Sběr

Operátory jsou AI subagenti v prohlížeči Codex In-app Browser. Přednost dostává 22 dosud neměřených veřejných dev/val otázek. Další operátor odděleně připravuje deset nových neveřejných otázek; původní publikované CIT-031–040 se za skrytý test nevydávají. Nové otázky i jejich reference jsou vytvořeny s pomocí AI, **nejsou nezávisle schváleny člověkem**.

Před konstrukcí nových otázek byly uchovány neměnné byte kopie a SHA-256 šablon P1, P2 a P3A v obou jazycích. P3A je v tomto doplňku předem zvolený kandidát. Není vydáván za vítěze validačního porovnání ani za původní `P3_final`. Otázky nesmí vést k následným úpravám promptu.

Sběr ukládá původní odpověď, skutečné časy, použitou šablonu, viditelnou konfiguraci a snímek. Údaje, které rozhraní neukazuje, jsou `unknown`. Rozdíly účtu, tarifu a rozhraní vůči původnímu pilotu jsou odchylky; výsledky se neslévají do společného produktového žebříčku. Případná nemožnost přístupu se dokládá konkrétní chybou, nikoli náhradní vymyšlenou odpovědí.

6.c. Hodnocení

Aktuální výstupy v `results/ai-review-2026-10-13-v2/` představují **pomocné AI hodnocení** podle existující rubriky. Nejsou prací Reného Mrákavy ani Jana Duba. Pokud nebylo možné otevřít přesně citovaný zdroj, je tato skutečnost zachována; jiný kontrolní zdroj nedokazuje podporu původní citace. Přístupové selhání není důkazem FAB.

Skóre se vždy uvádí s počtem posouzených odpovědí, úloh a dvojic, rozsahem zdrojové kontroly a identitou AI hodnotitele. Nejistota z převzorkování úloh nezahrnuje chyby samotného AI hodnocení. Nelze ji vydávat za lidskou shodu nebo použít pro potvrzující test H1/H2 podle původního protokolu.

6.d. Co doplněk nenahrazuje

Zadání výslovně vyžaduje alespoň jednu složku skutečného lidského hodnocení. AI může připravit ratingy, podklady i vysvětlení, ale nemůže tuto podmínku splnit pod identitou členů týmu. Plné porovnání všech tří promptových podmínek a všech produktů musí být doloženo vyplněnou maticí; samotná existence šablon nebo dosažení 40 úloh úplnou matici nedokazuje.

Aktuální součty a dostupné tabulky jsou v kapitole Výsledky skutečného pilotu. Uvedené neúplnosti jsou stav dat, nikoli dodatečně odsouhlasené výjimky ze zadání.

6.e. Audit exportů a příprava lidské práce

Kanonický registr používá collection/run_id, samostatné template a rendered SHA a skutečná metadata. Původní chybné clipboard exporty jsou zachované; čtyři odpovědi byly z dochovaných AX a PNG obnovené do nové verze. Nový sběr čte přímo konkrétní response DOM a zachovává skutečné href. Odstraněn byl jediný UI nadpis identifikující produkt v podkladu pro zaslepené hodnocení; odpověď ani citace se nepřepisují. SUP-H002/P2 se ve výběru započítá pouze jeho náhradou.

Reference doplňku byly jednotně opravené po sběru a označené jako AI ověřené. Deset otázek už je zveřejněných; není to neviděný test pro další ladění. Zaslepený exportátor ověřuje všechny vstupní hashy, odděluje identifikační klíč a nepředvyplňuje ratingy. Povinné skutečné lidské hodnocení: Předání nezávislým hodnotitelům.

7. Předání nezávislým hodnotitelům

Správce rozdělí dva oddělené balíčky. První hodnotitel má všech 92 způsobilých odpovědí, druhý náhodný výběr ≥25 % z každého strata fáze × produkt × podmínka. Identity produktů, podmínek, klíč a pomocné AI ratingy zůstávají u správce. Hodnotitelé pracují samostatně do odevzdání původních listů.

1. Přečíst README, rubriku a kalibrační pravidla v balíčku. Ponechat anonymní ID.

2. V answers_to_rate.csv zkontrolovat celou odpověď, RF/OF/RC a nezávisle ověřit referenci. Zapsat correctness 0–2, fakta/evidenci, požadavky a skutečný čas práce.
3. V pairs_to_rate.csv zkontrolovat návrhy dělení, doplnit opomenutá tvrzení a přesné vztahy k citacím. Nehodnotit pouhou přítomnost URL jako podporu.
4. Pro každý skutečný pár uvést S2/S1/S0/NA/FAB, přesný důkaz, datum a locator. Podpůrná citovaná věta není další tvrzení modelu. Chybějící OF se netrestá.
5. Zachovat původní URL, značky a nepřístupné zdroje. Nativní cíle bez zachované vazby se nesmí doplnit domněnkou. Návrh, který není faktickým párem, označit NONE.
6. Odevzdat oba původní CSV samostatně správci. Teprve potom řešit neshody; shoda/kappa se vypočítá z původních nezávislých ratingů, nikoli konsenzu.

U časově omezených otázek se používá UTC datum doloženého odeslání v reference_valid_as_of; jde o den běhu, ne den hodnocení. Původní RUN_DAY reference zůstala beze změny.

CSV jsou UTF-8; pro otevření v tabulkovém editoru zvolit import s čárkou a uvozovkami. Prázdná pole jsou určena k vyplnění, nikoli nuly. Všechny zveřejněné zdrojové reference jsou zatím návrh k nezávislé kontrole. Nevydávat vyplněné exploratorní listy za zpětné G1/G2/G3 nebo nově skrytý test.

Po návratu ratingů správce uchová originály mimo Git, připojí audit neshod, spočítá výsledky se selháními a jasně označí exploratorní rozsah. Pro původní plný potvrzující protokol je ještě potřeba nová skrytá sada, úplná produktová matice, skutečný výběr P3 a včasná schválení bran.

8. Analýza osmi skutečných pilotních úloh

Rozbor pokrývá **8 unikátních úloh** z pilotu (CIT-001, 003, 004, 005, 008, 012, 013, 020) a obsahuje úspěchy, citační problémy i provozní selhání. U každé úlohy je uveden konkrétní běh, pozorování v originální odpovědi a kontrola proti primárnímu zdroji (snapshot s časem a SHA-256 mimo Git). Je to **doplňková analýza s pomocí AI operátora před zmrazením protokolu**, ne nezávislý lidský rating ani výsledek finální testovací sady.

Typ nálezu	Úlohy	Co ukazují
Úspěch	CIT-003, CIT-012, CIT-013, CIT-020	Správná hlavní hodnota podpořená primárním zdrojem; rozlišení časových údajů a přiznání nejistoty
Citační riziko	CIT-001, CIT-008 (Perplexity)	Inline odkaz nesouhlasí se seznamem zdrojů; hranice věku přisouzena jinému článku Ústavy
K lidskému přezkumu	CIT-004 (Grok), CIT-005	Doplňková tvrzení nad rámec reference; zdroje typu agregátor místo úředního textu
Provozní selhání	CIT-004 (ChatGPT)	Chyba načtení po částečném výstupu; první pokus zachován

8.a. CIT-001 · riziko citace (Perplexity, původní pilot)

Pozorování: inline DOI `NEJMoa2200674` se liší od DOI v seznamu zdrojů, `NEJMoa2034577`. **Kontrola:** správných 95 % v hlavní větě rozpor neodstraňuje; čtenář může odkaz s tvrzením zaměnit (E4). Odpověď i oba cíle jsou zachovány, mechanismus vzniku je *unknown*.

8.b. CIT-003 · úspěch (ChatGPT, Grok)

Pozorování: poločas ≈ 5 730 let, přeměna na dusík-14, definice poločasu s odkazem na NIST. **Kontrola:** NIST údaje podporuje. Přípustná hodnota není chyba jen proto, že jiná evaluace uvádí 5 700 ±30 let. Dobrovolné podrobnosti Groku vyžadují samostatnou kontrolu.

8.c. CIT-004 · smíšený výsledek a provozní selhání (Grok, ChatGPT)

Pozorování: Grok rozlišil 1 603,296 m a trigonometrický bod 1 602,02 m, ale T2 navíc tvrdí polohu u kaple a vzdálenost 3,5 m. ChatGPT po částečném textu skončil chybou načtení. **Kontrola:** Zeměměřický úřad podporuje oba výškové údaje, ne kapli ani 3,5 m; T2 je nutné rozdělit (E2). Selhání ChatGPT je `failed/tool_error`, ne nahrazený běh; částečný výstup je uchován.

8.d. CIT-005 · úspěch s výhradou (Grok, ChatGPT)

Pozorování: odpovědi odlišují 1. 1. 2024 od plné aplikace 1. 7. 2024; Grok cituje i právní agregátory a obecní zdroje. **Kontrola:** MMR podporuje hlavní datum. Správná odpověď ještě neznamená, že každý její odkaz je primární nebo podporuje všechny podrobnosti.

8.e. CIT-008 · chybný předpoklad (ChatGPT úspěch, Perplexity chybný locator)

Pozorování: ChatGPT opraví 35 let na 40 a rozliší Sněmovnu (21) a Senát (40). Perplexity věk také opraví, ale přisoudí jej čl. 16 odst. 2. **Kontrola:** Ústava na PSP, čl. 19 odst. 1–2, opravu potvrzuje. Čl. 16 odst. 2 řeší počet senátorů a období, ne věk: správné číslo s chybným locatorem (E5). Text zůstává nezměněn.

8.f. CIT-012 · úspěch (ChatGPT)

Pozorování: správně SBOM, EO 14028 z 12. 5. 2021, odlišená publikace 17. 5. 2021, zmínka o licenční analýze. **Kontrola:** původní EO ve Federal Register, §4(e)(vii), §4(f), §10(j), podporuje definici, data i použití. Datum podpisu a publikace se nesmějí zaměnit (E5).

8.g. CIT-013 · úspěch (ChatGPT)

Pozorování: přesné číslo 10 524 167 a rozhodný okamžik půlnoc 26./27. 3. 2021. **Kontrola:** ČSÚ údaje potvrzuje. Rozpor roku vydání v textu a metadatech stránky není důvodem označit počet za chybný.

8.h. CIT-020 · práce s nejistotou (všechny čtyři produkty)

Pozorování: odlišena neznámá data narození, doložený křest a tradice 23. 4. Perplexity C3 navíc používá „earliest plausible birth date“. **Kontrola:** Shakespeare Birthplace Trust přiznání nejistoty podporuje; silnější tvrzení o nejdřívějším dni vyžaduje další kontrolu (E3).

Zdroje pro tento rozbor byly skutečně staženy se snapshoty, časem a SHA-256 mimo Git; veřejná provenance je součástí exportu rozšířeného pilotu. Kanonický kontrolní zdroj výše není automaticky důkazem S2 pro jinou URL, kterou citoval produkt. Nezávislí hodnotitelé musí posoudit každý původní pár, celý text odpovědi a všechny dobrovolné doplňky. Kódy chyb zde označují nálezy nebo výslovná rizika k přezkumu, nikoli vyplněné ratingy pod identitou Reného a Jana.

U ChatGPT CIT-004 se interval od odeslání do terminálního pozorování chyby 137,738 s odděluje od původního částečného zachycení po 18,878 s. Ani jeden není přesná generační latence. Některé snímky zachycují jen prompt nebo neúplný viewport; raw odpovědi a terminální JSON/TXT jsou autoritativní.

Retrieval, attribution a generation jsou hypotézy příčin; bez přímého důkazu uvádíme *unknown*. Systematická četnost chyb, srovnání P1/P2/P3 a lidská shoda vyžadují plný experiment (Plán, role a další kroky); osm úloh jej nenahrazuje.

9. Limity a platnost výsledků

Sběr nyní pokrývá 40 různých otázek a 93 věcných odpovědí, ale produktová matice je neúplná. Gemini má 9 úplných tripletů; ostatní produkty nemají stejné pokrytí. Claude nemá dokončenou odpověď. Odpovědi z různých účtů, tarifů či rozhraní se neslévají do obecného žebříčku. Naměřené jsou produkty jako celky, nikoli izolované modely.

Deset doplňkových otázek bylo připravených s pomocí AI po fixaci šablon, nesplňuje původní požadovanou směs typů úloh a bylo zveřejněno. Jejich použití nedokládá nezávislý skrytý test, G1/G2 nebo validační výběr P3. Pro další potvrzující experiment je nutná nová nezávislá skrytá sada.

Pomocné AI ratingy byly opravené po významových kontrolách zdrojů. To ukazuje potřebu skutečných lidských hodnotitelů. Jejich listy jsou zaslepené, ratingy prázdné a klíč oddělený. Lidská shoda dosud není naměřená. Reference mají post-collection AI evidenci, nikoli nezávislé schválení.

Citační CI se týká pouze tří účelově vybraných úloh, obsahový CI osmi. Tyto intervaly nezahrnují chyby segmentace ani hodnotitele. Dokončený subset může nadhodnotit výsledek vynecháním selhání, proto uvádíme i nulový terminální pokus. Čísla neprokazují H1/H2 ani trvalé rozdíly mezi produkty.

Webové zdroje se mění a některé čtečky mění URL. Při použití zrcadla je nutné prokázat totožnost dokumentu; správné referenční URL nepodporuje automaticky jinou citaci produktu. Nezachycené cíle nativních značek zůstávají neznámé. Snímky mohou zachycovat pouze část viewportu; úplný text a originální DOM/AX jsou zachované samostatně. Opravy exportů jsou auditované a nepřepisují originály.

Časy zahrnují čekání operátora a zachycení, ne izolovanou generační latenci. Tokeny, kredity, ceny a nastavení, které UI neukazuje, zůstávají unknown. Časová selhání a opakování se zachovávají; překročení 180s limitu při pozorování se neskrývá zkrácením razítek. Žádné finální hodnocení se nepublikuje pod identitou člověka.

10. Plán, role a další kroky

Plný experiment má **500 analytických odpovědí** (5 produktů × 3 prompty × úlohy; P2 na testu 3×) plus pilot navíc. Pilot je hotový; plný experiment přesahoval dostupný čas a rozpočet. Níže je postup, kterým jej lze bez změny návrhu provést.

10.a. Brány

Tři brány dávají studii pevné pořadí a zabraňují ladění na testu.

Brána	Co se zmrazí	Kdy
G1	Protokol, data, rubrika, P1/P2 a kód	před prvním analytickým během

Brána	Co se zmrazí	Kdy
G2	Vítězný prompt P3_final	před otevřením testovací sady
G3	Konec hodnocení a audit neshod	před finálním skórováním

10.b. Role

Role	Odpovědnost	Omezení
Koordinátor / analytik	Protokol, metadata, skripty, bootstrap, reprodukovatelný balíček	–
Správce dat a ověřovatel referencí	Soukromý test, hash, zaslepení listů, ověření RF/OF	Nesdílí test s autorem promptu
Autor promptu	P2, kandidáti P3, changelog	Neotevře test před zmrazením P3
Hodnotitelé	Nezávislé ratingy, dvojité hodnocení ≥ 25 %	Nehodnotí vlastní běhy

Plánovaní hodnotitelé jsou René Mrákava a Jan Dub (správce soukromého testu: René, autor promptu: Jan). Nikolas Nosál zajišťuje analýzu, dokumentaci a sběr. Přiřazení rolí není provedené hodnocení ani podpis brány. Pilotní odpovědi sbíral AI operátor v Chromu; jeho výstupy hodnotí lidé.

10.c. Rozšíření na plný experiment

1. Lidská kontrola referencí (RF/OF s locatorem, datem a snapshotem) a schválení soukromého testu.
2. Nezávislá kalibrace obou hodnotitelů na pilotních odpovědích a vyplnění připravených listů.
3. Sladění konfigurace účtů a podpis **G1**; sběr dev/val, volba P3, **G2**, test, **G3**.
4. `score.py --final`: přesnost, úplnost, správnost, intervaly, H1/H2, analýza chyb.

10.d. Selhání a opakování

Typ selhání	Příklad	Opakování	Jak se počítá
Výstup modelu	Odmítnutí, bez citací, halucinace	Ne	Hodnotí se (bez citací = přesnost 0)
Neplatný formát	P2 bez sekce ZDROJE	Ne	Hodnotí se, zapíše se validita formátu
Chyba nástroje / limit / výpadek	„Vyhledávání se nezdařilo“, denní limit	1×	První pokus i výsledek zvlášť
Chyba studenta	Špatný prompt, zapnutý hloubkový výzkum	Svázaná náhrada	Původní řádek zůstává

Každé selhání a ruční zásah je v metadatech (`failure_type`, `retries`, `manual_intervention`); neúspěšné pokusy se nemažou. Úplné příkazy s manifesty a soukromými cestami jsou v `HANDOFF.md`.

10.e. Aktuální stav po kontrole 13. 10. 2026

40 různých úloh, 93 uložených věcných odpovědí / 92 způsobilých podkladů; 9 Gemini tripletů. Zaslepené listy pro skutečné hodnotitele jsou připravené (Předání nezávislým hodnotitelům). Aktuální AI metriky pocházejí z opravované verze 2 (Výsledky skutečného pilotu); úplná produktová matice a původní G1/G2/G3 zůstávají otevřené.

11. Přílohy

11.a. Příloha A: odevzdávané artefakty a reprodukce

Repozitář obsahuje metodiku, skutečný pilot a dostupné doplňkové výstupy. Ne všechny povinné části zadání jsou dokončené; tabulka rozlišuje nástroje, návrhy a skutečně provedené měření. Omezení času samo o sobě není schválenou výjimkou z minimálních požadavků zadání.

#	Povinný výstup	Umístění	Stav
1	Výzkumný protokol	`PROTOCOL.md`, `freeze/README.md`	Hotový (nezmrazeno)
2	Benchmarková data	`data/` (dev 20, val 10)	30 veřejných + 10 zveřejněných doplňkových otázek; nezávislá kontrola chybí
3	Prompty a historie	`prompts/`, `prompts/CHANGELOG.md`	P1, P2, kandidáti P3; P3_final se v omezeném rozsahu nevybíral
4	Metadata běhů	`runs/`, `scripts/make_run_plan.py`	Kanonický registr 93 uložených věcných odpovědí
5	Kód a rubrika	`scripts/`, `annotation/`, `tests/`	Hotovo a testováno na syntetických datech
6	Výsledky a nejistota	Výsledky skutečného pilotu, `results/pilot/`	Pilot, AI audit v2 a intervaly; G3 skóre chybí
7	Analýza ≥ 8 úloh	Analýza osmi skutečných pilotních úloh	8 skutečných úloh, úspěchy i selhání
8	Závěrečná zpráva	`docs/`, `docs/exports/project.pdf`	Tato zpráva
–	Zdroje a použití AI	Příloha C: zdroje a použití AI	Příloha C
–	Worksheet	`docs/deliverables/worksheet.md`	Aktuální pilot, doplněk a AI audit

Dosud chybí nezávislé ratingy, úplná matice a schválené brány G1–G3. Dostupné intervaly AI auditu se uvádějí samostatně.

11.a.i. *Reprodukce bez přístupu k produktům:*

Stačí Python 3.9+ a standardní knihovna; žádné klíče ani účty.

```
python3 scripts/validate_cases.py --no-test
PYTHONDONTWRITEBYTECODE=1 python3 -m unittest discover -s tests -v
python3 docs/figures/make_figures.py      # obrázky z results/pilot/
cd docs && uv run --locked myst build --pdf
```

Testy a demo používají syntetická data a ověřují software, ne produkty. Surové pilotní odpovědi mají otisky SHA-256 a nemění se; skutečné plány, klíče a hodnocení patří mimo Git (viz `HANDOFF.md`). Složky `runs/*/avast/` jsou původní názvy evidence z pilotu; sběr probíhal v Chromu.

11.a.ii. *Etika a data:*
Úlohy jsou syntetické a týkají se veřejných faktů; neobsahují osobní údaje ani důvěrná data. K pilotním odpovědím nepatří přihlašovací údaje ani profily účtů.

11.a.iii. *Aktuální stav po kontrole 13. 10. 2026:*
40 různých úloh, 93 uložených věcných odpovědí / 92 způsobilých podkladů; 9 Gemini tripletů. Zaslepené listy pro skutečné hodnotitele jsou připravené (Předání nezávislým hodnotitelům). Aktuální AI metriky pocházejí z opravované verze 2 (Výsledky skutečného pilotu); úplná produktová matice a původní G1/G2/G3 zůstávají otevřené.

11.b. Příloha B: pojmy a zkratky

Pojem	Význam
Produkt	Model + vyhledávání + rozhraní jako celek (např. webové ChatGPT)
Tvrzení	Atomický faktický výrok v odpovědi
Dvojice	Tvrzení a zdroj, který k němu produkt skutečně připojil
S2 / S1 / S0	Zdroj tvrzení plně / částečně / nepodporuje
NA	Zdroj se nepodařilo přečíst; **FAB** – zdroj neexistuje
RF / OF / RC	Povinná fakta / nepovinná fakta / požadavky na formát a zdroje v referenci úlohy
P1 / P2 / P3	Společný výchozí / strukturovaný / optimalizovaný prompt
Dev / val / test	Vývojová, validační a soukromá testovací sada
G1 / G2 / G3	Brány: zmrazení protokolu / promptu P3 / konec hodnocení
Citační přesnost	Podíl S2 mezi všemi explicitními dvojicemi odpovědi (hlavní metrika)
CI	Interval spolehlivosti (párový bootstrap po úlohách)
κ	Cohenova kappa, shoda dvou hodnotitelů mimo náhodu
unknown	Hodnota, kterou rozhraní nezobrazilo; nikdy se nenahrazuje odhadem

11.c. Kontrola referencí před G1
Datum kontroly: 12. 10. 2026. Read-only AI reviewer prošel všech 30 veřejných dev/val případů; operátor zkontroloval významné nálezy. Tato kontrola připravuje podklady pro nezávislého lidského ověřovatele. Není lidskou verifikací, ratingem produktových odpovědí ani úplným `source_evidence.csv` se snapshoty všech RF/OF.

- **CIT-001** — Originální článek, Europe PMC XML, Abstract Results a Table 2. 95 %, 95% credible interval 90,3–97,6. NEJM přímo vracel 403.
- **CIT-002** — WHO, Strong/Conditional recommendation. Volné cukry <10 % energie; <5 % podmíněné doporučení; guideline 2015.
- **CIT-003** — NNDC ENSDF, parent 14C; Stuiver–Polach, § 3. 5 700 ±30 let; historický konsenzus 5 730 ±40 a konvenční Libbyho hodnota 5 568 se nesmějí zaměnit.

- **CIT-004** — Zeměměřický úřad, odstavec měření a staré kóty. 1 603,296 m; 1 602 je zaokrouhlená kóta jiného trigonometrického bodu 1 602,02 m. Měření je z 2014.
- **CIT-005** — MMR, úvod; text zákona, § 334a–335. Běžné stavby od 1. 7. 2024; formální účinnost a přechodné režimy odlišeny.
- **CIT-006** — e-Sbírka, § 230 odst. 1. Přímé otevření neposkytlo čitelný text. Současná dvouletá sazba je zatím jen indexovaný podklad. Starý policejní PDF má jinou sazbu.
- **CIT-007** — GFŘ PDF, § 2.2, s. 3–4. RF jídlo 12 % potvrzen. OF nápoje opraveno o výjimky; historické OF „předtím 10 %“ ještě samostatně ověřit.
- **CIT-008** — Ústava, PSP, čl. 19 odst. 2. Věk 40 let; premisa 35 je chybná.
- **CIT-009** — NVD API, cvssMetricV31, Primary NVD. CVSS 3.1: 10.0, CRITICAL.
- **CIT-010** — Microsoft ESU, úvod a How to get Windows 10 ESU. Konec podpory 14. 10. 2025, nynější spotřebitelské ESU do 12. 10. 2027. Historické OF původně 13. 10. 2026 zbývá ověřit; blog vracel 403.
- **CIT-011** — UCLA / Kleinrock, úvod a IMP log. „lo“, 29. 10. 1969, UCLA do SRI.
- **CIT-012** — GovInfo EO, § 4; NTIA, úvod. SBOM definice, EO 14028 z 12. 5. 2021; NTIA minimum elements 12. 7. 2021.
- **CIT-013** — ČSÚ první výsledky, první dva odstavce. 10 524 167; půlnoc 26./27. 3. 2021. Stránka má rozpor textového roku vydání a metadat, nikoli počtu.
- **CIT-014** — Eurostat původní release; aktuální API, rok 2023. Původně 24,5 %, databáze aktualizovaná 15. 9. 2026: 24,579 %, zaokrouhleně 24,6 %. Hodnotit správnou verzi, ne trestat doloženou revizi.
- **CIT-015** — ECB Bulletin 6/2026, Summary, část Monetary policy decisions a metadata. MRO 2,65 % od 16. 9.; publikace 24. 9. splňuje 30 dnů k datu kontroly. Zpráva 10. 9. již nikoli.
- **CIT-016** — Bitslog původní analýza, metodické předpoklady. Odhad těžby nedokazuje přesné současné vlastnictví BTC. Celý OF rozsah 0,6–1,1 milionu nebyl ověřen, BitMEX vracel 404.
- **CIT-017** — Historie UK, rok 1348. 7. 4. 1348, Karel IV.
- **CIT-018** — Archiv Národního divadla, světová premiéra. 29. 10. 1787, Stavovské divadlo; historický název Nosticovo tento odstavec samostatně nepotvrdil.
- **CIT-019** — MZV; PSP federace, Úvod. Samostatný stát 1. 1. 1993, federace od 1. 1. 1969. Přesný den přejmenování 6. 3. 1990 dosud pouze index e-Sbírky.
- **CIT-020** — Shakespeare Birthplace Trust, Parish Register. Přesné narození není zaznamenáno; křest 26. 4. 1564, tradice narozenin 23. 4.
- **CIT-021** — Nobel Foundation, Prize motivation. Zákon fotoelektrického jevu, cena za 1921, převzetí 1922.
- **CIT-022** — EHT release, úvod. EHT, M87*, 10. 4. 2019.
- **CIT-023** — EUR-Lex, čl. 83 odst. 5. Limit doplněn o podnik a předchozí finanční rok. Přímé HTML/PDF končilo robot challenge; nejde o dokončené primární ověření.
- **CIT-024** — Evropská komise, 2030 climate target. Alespoň −55 % čistých emisí proti 1990. OF čl. 4 odst. 1 přímo v EUR-Lex neotevřen.
- **CIT-025** — Originální arXiv, metadata a abstrakt. Název, Patrick Lewis et al., NeurIPS 2020, arXiv:2005.11401. Absolutní historická priorita termínu samostatně neprokázána.
- **CIT-026** — RFC Editor, hlavička. RFC 9114, červen 2022.
- **CIT-027** — ČSÚ srpen, Míra nezaměstnanosti; ÚP září, odrážky 1–2. ČSÚ VŠPS 15–64 očištěně 3,4 % za srpen; ÚP PNO 5,0 % za září. ČSÚ 15–74 varianta 3,2 %. Čísla/období/definice odlišit.
- **CIT-028** — MPSV, titul a mechanismus. 20 800 Kč měsíčně pro 2025.

- **CIT-029** — UK, historický odstavec. Stavba 1357–1402. RF „přesnou cenu v dnešních Kč nelze určit“ není přímo podpořen zdrojem; potřebuje přezkoumání metodiky převodu a nákladů.
- **CIT-030** — Nobel Foundation, laureát. Jaroslav Seifert, 1984.

Následná kontrola operátora doplnila dvě historické mezery: Finanční správa, 6. 6. 2023, s. 2, dokládá 10 % pro stravování; Microsoft News Center, 30. 6. 2025, první varianta spotřebitelského ESU, dokládá původní konec 13. 10. 2026. Historický konsenzus uhlíku-14 5 730 ±40 let dokládá také Radiocarbon, Notice to Readers, PDF s. 3; tento přesný údaj neodvozujeme jen ze Stuiver–Polach.

Před podpisem G1 je třeba vyřešit ostatní uvedené mezery a získat lidskou kontrolu každého RF i OF s konkrétní hodnotou, locatorem, datem a soukromým snapshotem/hash. Žádné přístupové selhání není důkazem neexistence zdroje. Dynamické reference se navíc ověřují podle UTC dne každého analytického běhu.

11.c.i. *Aktualizace AI kontroly 13. 10. 2026:*

Deset nových zveřejněných otázek má opravenou jednotnou verzi RF/RC v `runs/reference-correction-2026-10-13/`: 18 RF, 2 RC, datované otevřené oficiální zdroje a snapshot SHA. Otázky a prompty se neměnily; korekce vznikla po sběru. Opravené zdrojové rozhodnutí pro pilot je v `results/ai-review-2026-10-13-v2/`. Přesně citovaná stránka Hradu je nyní čitelná, ČSÚ uvádí rozhodný okamžik přímo, EO §10(j) podporuje licenční analýzu a hash není jedním ze sedmi minimálních prvků NTIA z července 2021. Původní snapshoty a tehdejší přístupové chyby zůstaly zachované. Nejde o lidské schválení referencí ani původní G1.

11.d. Příloha C: zdroje a použití AI

11.d.i. *Zadání a metodické zdroje:*

- CZAI Assignment 1: porovnání AI asistentů, zadání a šablona worksheetu (`assignment/CZAI_Assignment_1.pdf`, `assignment/2026-AI-Student-worksheet.md`), 2026.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. (shoda hodnotitelů, κ)
- Efron, B. (1979). Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, 7(1), 1–26. (bootstrapové intervaly)
- Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158), 209–212. (intervaly pro podíly)

11.d.ii. *Zdroje použité při kontrole referencí a v analýze chyb:*

Primární zdroje s odkazy jsou uvedeny přímo v tabulkách: pro všech 30 veřejných úloh v příloze Kontrola referencí před G1 a pro osm pilotních úloh v kapitole Analýza osmi skutečných pilotních úloh (např. NIST, Zeměměřický úřad, Ústava ČR na PSP, Federal Register, ČSÚ, Shakespeare Birthplace Trust, Europe PMC). U každého je uveden locator (část stránky) a datum kontroly; soukromé snapshoty mají čas a SHA-256 a jsou součástí auditní evidence mimo veřejný repozitář. Skutečné odpovědi produktů se citují z exportů v `runs/pilot-2026-10-12/` a `runs/pilot-2026-10-13/`.

11.d.iii. *Nástroje:*

Python (standardní knihovna) pro skripty a testy, MyST Markdown a Typst pro sazbu zprávy. Zdrojové kódy a verze jsou v `scripts/`, `tests/`, `pyproject.toml` a `uv.lock`.

11.d.iv. *Použití AI:*

Odpovědi hodnocených produktů (ChatGPT, Gemini, Claude, Perplexity, Grok) jsou předmětem studie. Sběr pilotních odpovědí z webových rozhraní, pomocná kontrola referencí, návrhy komentářů a část nástrojů a textu vznikly s pomocí AI agentů pod dohledem týmu. Všechny výstupy AI jsou v projektu označeny (např. `SUPPLEMENTARY_AI_REVIEW_NOT_HUMAN_VERIFIED`), neslouží jako nezávislé lidské hodnocení ani jako jediný důkaz závěrů a původní hlavní metrika nadále vyžaduje lidské ratingy. Od 13. 10. 2026 je navíc odděleně zveřejněno pomocné AI hodnocení; jeho metoda a omezení jsou v příloze Doplňkový sběr a výslovně označené AI hodnocení. Toto hodnocení se nevydává za lidskou práci členů týmu. Zodpovědnost za obsah nesou autoři.